دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر
گروه هوش مصنوعی

ریزتنظیم مدل‌های زبانی برای ناوردایی معنایی در فضای نهان خودرمزگذارهای پراکنده

پروژه کارشناسی مهندسی کامپیوتر تمرکز هوش مصنوعی

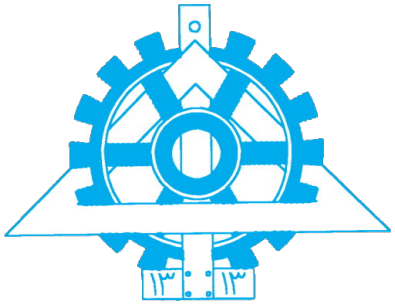
رضا چهرقانی

استاد راهنما

دکتر مصطفی توسلی‌پور

۱۴۰۵


بسم الله الرحمن الرحيم



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر
گروه هوش مصنوعی



ریزتنظیم مدل‌های زبانی برای ناوردایی معنایی در فضای نهان خودرمزگذارهای پراکنده

پروژه کارشناسی مهندسی کامپیوتر گرایش هوش مصنوعی

رضا چهرقانی

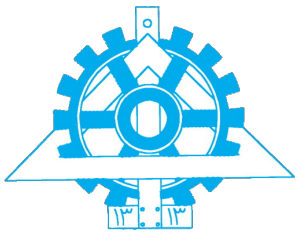
استاد راهنما

دکتر مصطفی توسلی‌پور

۱۴۰۵



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



گواهی دفاع از پروژه کارشناسی

هیأت داوران پروژهٔ کارشناسی آقای / خانم رضا چهرقانی به شمارهٔ دانشجویی ۸۱۰۱۰۱۴۰۱ در رشتهٔ مهندسی کامپیوتر – تمرکز هوش مصنوعی را در تاریخ ..... با عنوان «ریزتنظیم مدل‌های زبانی برای ناوردایی معنایی در فضای نهان خودرمزگذارهای پراکنده»

	به عدد	به حروف
با نمرهٔ نهایی		

و درجهٔ [ ] ارزیابی کرد.

ردیف	مشخصات هیأت داوران	نام و نام خانوادگی	مرتبهٔ دانشگاهی	دانشگاه یا مؤسسه	امضا
۱	استاد راهنما	دکتر مصطفی توسلی‌پور	استادیار	دانشگاه تهران	
۲	استاد داور	دکتر یداله یعقوب‌زاده	استادیار	دانشگاه تهران	

نام و نام خانوادگی معاون پژوهشی
دانشکده / گروه:
تاریخ و امضا:

نام و نام خانوادگی معاون آموزشی پردیس
دانشکده‌های فنی:
تاریخ و امضا:

تعهدنامهٔ اصالت اثر

باسمه تعالی

اینجانب رضا چهرقانی تأیید می‌کنم که مطالب مندرج در این پروژه حاصل کار پژوهشی اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آن‌ها استفاده شده است مطابق مقررات ارجاع گردیده است. این پروژه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتری ارائه نشده است.

نام و نام خانوادگی دانشجو: رضا چهرقانی

تاریخ و امضای دانشجو:

کلیهٔ حقوق مادی و معنوی این اثر
متعلّق به دانشگاه تهران است.

قدردانی

از استاد راهنمای گران‌قدرم، دکتر توسلی‌پور، برای راهنمایی‌های ارزنده و صبورانه در سرتاسر این پژوهش، صمیمانه سپاس‌گزارم.

از داوران محترم این پایان‌نامه، برای وقتی که صرف مطالعه و ارزیابی این نوشتار کردند، کمال امتنان را دارم.

و سپاس ویژه از خانواده‌ام، برای حمایت بی‌دریغشان در طول این مسیر.

رضا چهرقانی

۱۴۰۵

چکیده

مدل‌های زبانی بزرگ، بازنمایی‌های برداری خود را عمدتاً با هدف پیش‌بینی نشانهٔ بعدی می‌آموزند، هدفی که لزوماً بازنمایی جمله را در راستای سنجه‌های معنایی مورد نظر انسان شکل نمی‌دهد. مجموعه‌دادهٔ PAWS این شکاف را آشکارا نشان می‌دهد: جفت‌جمله‌هایی با همپوشانی واژگانی بسیار بالا که برخی هم‌معنی و برخی ناهم‌معنی‌اند.

این پایان‌نامه روشی را برای ریزتنظیم کارآمد پارامتر یک مدل زبانی پیشنهاد می‌دهد که در آن، به‌جای اعمال مستقیم یک تابع هزینهٔ ناوردایی (که جفت‌های هم‌معنی را نزدیک و جفت‌های ناهم‌معنی را دور از هم نگاه می‌دارد) بر فضای خام جریان باقیماندهٔ مدل، این تابع هزینه بر کدهای نهان حاصل از عبور فعال‌سازی‌ها از یک خودرمزگذار پراکندهٔ از پیش‌آموزش‌دیده و ثابت اعمال می‌شود. انگیزهٔ این انتخاب، پدیدهٔ برهم‌نهی ویژگی‌ها در فضای خام مدل‌های زبانی است که اعمال مستقیم چنین هدفی را در آن فضا غیرقابل‌پیش‌بینی می‌کند.

این روش بر روی مدل Pythia-70m-deduped با تطبیق‌دهندهٔ لورا پیاده‌سازی و در یک شبکهٔ آزمایشی سیستماتیک-شامل چهار شرط آزمایشی (کنترل، ناوردایی در فضای خام، ناوردایی در فضای خودرمزگذار، و نسخهٔ تکمیل‌شدهٔ آن)، پنج مقدار برای وزن نسبی تابع هزینهٔ ناوردایی، و ده حالت متفاوت برای انتخاب لایهٔ هدف-با مجموع ۱۶۰ اجرای مستقل، ارزیابی شده است.

نتایج نشان می‌دهند اعمال تابع هزینهٔ ناوردایی در فضای خودرمزگذار، به‌طور پایدار، جداسازی بهتری میان جفت‌های هم‌معنی و ناهم‌معنی (بر حسب سطح زیر منحنی مشخصهٔ عملکرد گیرنده) نسبت به اعمال همان تابع هزینه در فضای خام یا نبود هرگونه هدف ناوردایی تولید می‌کند. این بهبود به‌شدت به عمق لایهٔ هدف (لایه‌های میانی-به-بعد، نه لایه‌های ابتدایی) و به وزن تابع هزینه وابسته است، و اعمال هم‌زمان چند لایه اثری فراجمع‌شونده دارد. بااین‌همه، بالاترین سطوح این بهبود با ناپایداری گذرا در آموزش و با افت اعتبار بازسازی خودرمزگذار همراه‌اند؛ منظم‌ساز پیشنهادی این هزینه را در بازهٔ وزن‌های پایین به‌طور کامل، و در بازهٔ وزن‌های بالا تنها تا حدی مهار می‌کند. بر همین اساس، این پایان‌نامه یک پیکربندی متعادل-با وزن میانه‌روتر-را معرفی می‌کند که تقریباً به همان بهبود دست می‌یابد، بدون تحمیل این هزینه. این پایان‌نامه با ترسیم این تصویر متعادل-به‌جای گزارش صرف بهترین نتیجهٔ خام-کاربرد تازه‌ای برای خودرمزگذارهای پراکنده، فراتر از نقش متداول آن‌ها در تفسیرپذیری پس‌ازآموزش، معرفی می‌کند.

واژگان کلیدی مدل‌های زبانی، خودرمزگذار پراکنده، ریزتنظیم کارآمد پارامتر، یادگیری تقابلی، تشخیص بازنویسی، تفسیرپذیری مکانیستی

فهرست مطالب

فهرست تصاویر ث

فهرست جداول چ

فهرست اختصارات خ

فصل ۱: مقدمه ۳

۱.۱ پیش‌گفتار ۳

۲.۱ بیان مسئله ۵

۳.۱ هدف تحقیق ۶

۴.۱ روش انجام تحقیق (خلاصه) ۷

۵.۱ نوآوری و اهمیت پژوهش ۷

۶.۱ تعریف واژه‌های کلیدی ۸

۷.۱ ساختار پایان‌نامه ۹

فصل ۲: مروری بر ادبیات موضوع ۱۱

۱.۲ مقدمه ۱۱

۲.۲ بازنمایی و شباهت معنایی در مدل‌های زبانی ۱۱

۱.۲.۲ از بازنمایی‌های ایستا تا بازنمایی‌های بافتاری ۱۱

۲.۲.۲ شفافیت پژوهشی خانوادهٔ مدل پایه ۱۳

۳.۲ تشخیص بازنویسی و سنجش شباهت معنایی متن ۱۳

۱.۳.۲ PAWS و شکاف میان شباهت لفظی و معنایی ۱۴
۲.۳.۲ سنجش جداسازی: از دقت طبقه‌بندی تا سطح زیر منحنی ۱۵
۴.۲ یادگیری تقابلی ۱۶
۱.۴.۲ مبانی و صورت‌بندی کلی ۱۶
۲.۴.۲ انتخاب نمونه‌های منفی و نقش نمونه‌های منفی سخت ۱۷
۳.۴.۲ جایگاه این پژوهش در ادبیات یادگیری تقابلی ۱۸
۴.۴.۲ ریسک فروپاشی بازنمایی ۱۸
۵.۲ تفسیرپذیری مکانیستی و خودرمزگذارهای پراکنده ۱۹
۱.۵.۲ برهم‌نهی و چندمعنایی ۱۹
۲.۵.۲ خودرمزگذارهای پراکنده به‌عنوان راه‌حل ۲۰
۳.۵.۲ فراتر از تحلیل: هدایت و مهندسی بازنمایی ۲۲
۴.۵.۲ نقد و محدودیت‌های کاربردی ۲۳
۶.۲ ریزتنظیم کارآمد پارامتر و حفظ رفتار مدل ۲۳
۱.۶.۲ روش‌های ریزتنظیم کارآمد پارامتر ۲۳
۲.۶.۲ حفظ رفتار مدل در حین ریزتنظیم ۲۴
۳.۶.۲ اعتبار ابزارهای سنجش ثابت در حین آموزش ۲۵
۷.۲ جمع‌بندی و جایگاه این پژوهش ۲۶

فصل ۳: روش پیشنهادی ۲۹
۱.۳ مقدمه ۲۹
۲.۳ نمای کلی معماری ۲۹
۳.۳ مدل پایه و تطبیق کارآمد پارامتر ۳۰
۴.۳ دادگان ۳۲
۵.۳ خودرمزگذار پراکندهٔ ثابت ۳۲
۱.۵.۳ ریسک رانش خودرمزگذار و راه‌حل پیشنهادی ۳۳
۲.۵.۳ فرمول منظم‌ساز بازسازی ۳۴

۶.۳ تابع هزینه ۳۴
۱.۶.۳ تابع هزینهٔ ناوردایی ۳۵
۷.۳ شرایط آزمایشی ۳۶
۸.۳ طرح آزمایش‌های شبکه‌ای ۳۷
۹.۳ معیارهای ارزیابی ۳۷
۱۰.۳ جزئیات پیاده‌سازی ۳۸

فصل ۴: نتایج ۳۹
۱.۴ مقدمه ۳۹
۲.۴ اثر شرط آزمایشی و وزن ناوردایی ۳۹
۳.۴ اثر انتخاب لایهٔ هدف و نمایهٔ کامل عمق ۴۱
۴.۴ هزینهٔ پایداری: سرگشتگی و اعتبار خودرمزگذار ۴۳
۱.۴.۴ سرگشتگی زبان‌مدل‌سازی ۴۳
۲.۴.۴ اعتبار بازسازی خودرمزگذار ۴۵
۳.۴.۴ نمونه‌ای از مصالحه: دو اجرای متضاد ۴۵
۵.۴ پیکربندی توصیه‌شده ۴۷
۶.۴ جمع‌بندی نتایج ۴۷

فصل ۵: جمع‌بندی و نتیجه‌گیری ۴۹
۱.۵ مروری بر پژوهش ۴۹
۲.۵ یافته‌های اصلی ۴۹
۳.۵ نوآوری پژوهش ۵۰
۴.۵ محدودیت‌های پژوهش ۵۱
۵.۵ پیشنهادهایی برای پژوهش‌های آینده ۵۱
۶.۵ سخن پایانی ۵۲

کتاب‌نامه ۵۳

پیوست آ: ابرپارامترها و جزئیات پیاده‌سازی ۵۷

پیوست ب: جداول کامل نتایج ۶۱

ب.۱ پیکربندی بهترین و بدترین بهبود خام، به ازای هر حالت انتخاب لایه ۶۱

ب.۲ میانگین بهبود بر حسب شرط و λ ۶۲

ب.۳ اعتبار بازسازی خودرمزگذار در گام پایانی ۶۳

واژه‌نامهٔ فارسی به انگلیسی **اول**

واژه‌نامهٔ انگلیسی به فارسی **پنجم**

فهرست تصاویر

۱.۳ نمای کلی معماری و جریان محاسبهٔ تابع هزینه. پنل بالا مسیر جفت‌جمله‌های PAWS را نشان می‌دهد که هم به تابع هزینهٔ ناوردایی و هم به منظم‌ساز بازسازی خود PAWS می‌انجامد؛ پنل پایین مسیر WikiText را نشان می‌دهد که هم به هزینهٔ زبان‌مدل‌سازی و هم به منظم‌ساز بازسازی WikiText می‌انجامد. کادرهای با حاشیهٔ نقطه‌چین (خودرمزگذار ثابت) پارامترهایی را نشان می‌دهند که هرگز به‌روزرسانی نمی‌شوند؛ گرادیان تنها از طریق تطبیق‌دهندهٔ لورای مشترک (که در هر دو پنل، همان وزن‌های یکسان است) به پارامترهای قابل‌آموزش بازمی‌گردد. ۳۱

۱.۴ میانگین بهبود AUROC در لایه(های) هدف، بر حسب وزن تابع هزینهٔ ناوردایی λ (میانگین روی هر ده حالت انتخاب لایه). خط افقی، سطح شرط C1 (فاقد λ) را نشان می‌دهد. . . ۴۱

۲.۴ چپ: میانگین بهبود AUROC بر حسب اینکه کدام لایهٔ منفرد هدف تابع هزینهٔ ناوردایی بوده (میله‌های خطا، بازهٔ کمینه تا بیشینه روی λها را نشان می‌دهند). راست: میانگین بهبود بر حسب تعداد لایه‌هایی که هم‌زمان تحت تابع هزینهٔ ناوردایی قرار گرفته‌اند. هر دو نمودار، میانگین شرایط C3 و C4 است. ۴۲

۳.۴ نمایهٔ کامل AUROC در تمام شش لایه، برای خط پایه در برابر بهترین پیکربندی (C3، لایه‌های هدف $\{۳, ۴, ۵\}$، $\lambda = ۱/۰$). ناحیهٔ سایه‌خورده، لایه‌های هدف را نشان می‌دهد. ۴۳

۴.۴ مصالحهٔ میان بهبود AUROC و سرگشتگی نهایی WikiText، برای هر یک از ۱۶۰ اجرا. محور افقی لگاریتمی است. دایرهٔ توخالی مشکی، پیکربندی توصیه‌شده را نشان می‌دهد؛ دایرهٔ توخالی قرمز، پیکربندی با بیشترین بهبود خام را. ۴۵

۵.۴ میانگین واریانس تبیین‌شدهٔ بازسازی خودرمزگذار در گام پایانی آموزش، به‌تفکیک شرط و λ (میانگین روی هر ده حالت انتخاب لایه). ۴۶

۶.۴ پویایی آموزش برای پیکربندی توصیه‌شده (آبی) در برابر یک پیکربندی تهاجمی‌تر جایگزین با $\lambda = ۱/۰$ و سه لایهٔ هدف هم‌زمان (قرمز). چپ: AUROC اعتبارسنجی PAWS. راست: واریانس تبیین‌شدهٔ بازسازی خودرمزگذار. ۴۶

فهرست جداول

۱.۲ جایگاه این پژوهش نسبت به نزدیک‌ترین خطوط پژوهشی مرورشده. ۲۶

۱.۳ شرایط آزمایشی. ستون «فضا» فضایی را نشان می‌دهد که تابع هزینهٔ ناوردایی در آن محاسبه می‌شود. ۳۶

۱.۴ میانگین و بازهٔ بهبود AUROC نسبت به خط پایه، در لایه(های) هدف، به تفکیک شرط آزمایشی. ۴۰

۲.۴ میانگین سرگشتگی WikiText در گام پایانی آموزش، به تفکیک شرط و λ. برای مقایسه، شرط C1 (بدون هیچ هدف ناوردایی) به سرگشتگی ۵۹٫۱ می‌رسد. ۴۴

آ.۱ ابرپارامترهای مدل، لورا و بهینه‌سازی. ۵۸

آ.۲ ابرپارامترهای دادگان. ۵۸

آ.۳ ابرپارامترهای تابع هزینه و ارزیابی. ۵۹

آ.۴ ساختار کامل شبکهٔ آزمایشی. هر سطر، تعداد اجراهای مربوط به آن شرط را در هر یک از ده حالت انتخاب لایه نشان می‌دهد؛ عدد کل، حاصل‌ضرب این مقدار در ۱۰ است. . . . ۵۹

ب.۱ پیکربندی بهترین و بدترین بهبود خام، به ازای هر حالت انتخاب لایه. ۶۲

ب.۲ میانگین بهبود AUROC، به تفکیک شرط و λ. ۶۳

ب.۳ میانگین واریانس تبیین‌شدهٔ بازسازی در گام پایانی، به تفکیک شرط و λ. ۶۳

فهرست اختصارات

A

AUROC . . . . . سطح زیر منحنی مشخصهٔ عملکرد گیرنده (Area Under the ROC Curve)

B

BCE . . . . . آنتروپی متقاطع دودویی (Binary Cross-Entropy)

BERT بازنمایی رمزگذار دوسویه از ترنسفورمرها (Bidirectional Encoder Representations from Transformers)

E

EWC . . . . . تحکیم وزن کشسان (Elastic Weight Consolidation)

K

KL . . . . . واگرایی کولبک-لایبلر (Kullback–Leibler Divergence)

L

LM . . . . . مدل زبانی (Language Model)

LoRA . . . . . تطبیق کم‌رتبه (Low-Rank Adaptation)

P

PAWS بازنویسی‌های متخاصم برآمده از جابه‌جایی کلمات (Paraphrase Adversaries from Word Scrambling)

PEFT . . . . . ریزتنظیم کارآمد پارامتر (Parameter-Efficient Fine-Tuning)

R

ReLU . . . . . یکسوساز خطی اصلاح‌شده (Rectified Linear Unit)

RLHF یادگیری تقویتی مبتنی بر بازخورد انسانی (Reinforcement Learning from Human Feedback) . . . .

ROC . . . . . مشخصهٔ عملکرد گیرنده (Receiver Operating Characteristic)

S

SAE . . . . . خودرمزگذار پراکنده (Sparse Autoencoder)

STS . . . . . شباهت معنایی متن (Semantic Textual Similarity)

فصل ۱

مقدمه

۱.۱ پیش‌گفتار

مدل‌های زبانی[1] بزرگ در سال‌های اخیر به ابزاری اساسی برای طیف وسیعی از کاربردهای پردازش زبان طبیعی[2] تبدیل شده‌اند. این مدل‌ها که عموماً بر پایهٔ معماری ترنسفورمر[3] [۳۰] ساخته می‌شوند، با پیش‌آموزش[4] بر روی حجم عظیمی از متن، بازنمایی‌های[5] برداری‌ای از زبان می‌آموزند که در لایه‌های میانی و در جریان به‌اصطلاح باقیمانده[6] شبکه جریان می‌یابند. سنجهٔ نهایی موفقیت این مدل‌ها اغلب توانایی آن‌ها در پیش‌بینی نشانهٔ[7] بعدی متن است، اما آنچه در عمل کاربرد این مدل‌ها را در وظایفی مانند بازیابی اطلاعات، پرسش‌وپاسخ، خلاصه‌سازی و تشخیص هم‌ارزی معنایی[8] تعیین می‌کند، کیفیت بازنمایی درونی‌ای است که این مدل‌ها از معنای جملات می‌سازند؛ به بیان دیگر، اینکه آیا فاصلهٔ میان بازنمایی دو جمله در فضای برداری مدل، واقعاً بازتابی از فاصلهٔ معنایی آن دو جمله هست یا صرفاً بازتابی از شباهت سطحی و واژگانی آن‌هاست.

پژوهش‌های متعددی نشان داده‌اند که این دو نوع شباهت-شباهت واژگانی و شباهت معنایی-می‌توانند به‌شدت از یکدیگر جدا باشند. مجموعه‌دادهٔ PAWS[9] [۳۳]، که مبنای عملی این پایان‌نامه نیز هست، دقیقاً برای آشکارسازی

[1] Language Model
[2] Natural Language Processing
[3] Transformer
[4] Pretraining
[5] Representations
[6] Residual Stream
[7] Token
[8] Semantic Equivalence
[9] Paraphrase Adversaries from Word Scrambling

همین شکاف طراحی شده است: جفت‌جمله‌هایی با همپوشانی واژگانی بسیار بالا که با جابه‌جایی ترتیب کلمات یا ترجمهٔ رفت‌وبرگشتی[۱۰] ساخته شده‌اند، به‌گونه‌ای که برخی از این جفت‌ها هم‌معنی[۱۱] و برخی دیگر، علی‌رغم شباهت ظاهری بسیار زیاد، ناهم‌معنی هستند. برای نمونه، دو جمله که تنها در ترتیب قرارگیری یک عبارت مکانی با یکدیگر تفاوت دارند می‌توانند معنای کاملاً متفاوتی داشته باشند، در حالی‌که از منظر یک مدل متکی بر همپوشانی واژگانی، تقریباً یکسان به نظر می‌رسند. سازندگان PAWS نشان دادند مدل‌های زمان خود که بر مجموعه‌داده‌های متعارف تشخیص بازنویسی[۱۲] آموزش دیده بودند، در تشخیص این جفت‌های دشوار به‌شدت ضعیف عمل می‌کنند (دقتی کمتر از ۴۰ درصد) [۳۳]، و این ضعف نشانه‌ای از آن است که بازنمایی‌های آموخته‌شده توسط این مدل‌ها، حتی وقتی روی وظایف شباهت معنایی به ظاهر موفق عمل می‌کنند، ممکن است بیش از آنکه معنا را رمزگذاری کرده باشند، به الگوهای سطحی واژگانی متکی باشند.

نقطهٔ آغاز این پایان‌نامه، مواجهه با همین مجموعه‌داده و همین مشاهده بود: وقتی جفت‌جمله‌های PAWS از یک مدل زبانی پیش‌آموزش‌دیده عبور داده شدند و بازنمایی آن‌ها در لایه‌های مختلف مدل بررسی شد، فاصلهٔ میان بازنمایی جفت‌های هم‌معنی و جفت‌های ناهم‌معنی، آن‌قدر که انتظار می‌رفت، از هم متمایز نبود. این مشاهده این پرسش را پیش کشید که آیا می‌توان مدل زبانی را طوری ریزتنظیم[۱۳] کرد که بازنمایی جفت‌جمله‌های هم‌معنی را به یکدیگر نزدیک‌تر و بازنمایی جفت‌جمله‌های ناهم‌معنی را از یکدیگر دورتر کند، بدون آنکه توانایی عمومی مدل در زبان‌مدل‌سازی[۱۴] را به‌طور محسوسی از دست بدهد.

پاسخ ساده‌ای که برای این پرسش می‌توان متصور شد، اعمال مستقیم یک تابع هزینهٔ تقابلی[۱۵] بر روی فضای پنهان[۱۶] خام خود مدل-یعنی همان جریان باقیمانده-است. اما فضای خام مدل، فضایی است که در آن هزاران مفهوم به‌طور همزمان و در قالب پدیده‌ای موسوم به برهم‌نهی[۱۷] [۸] در ابعاد مشترکی جای گرفته‌اند؛ در نتیجه، فشردن یا کشیدن این فضا در راستای یک هدف مشخص، می‌تواند به شکلی غیرقابل پیش‌بینی، مفاهیم نامرتبط دیگری را نیز جابه‌جا کند. در سال‌های اخیر، خودرمزگذارهای پراکنده[۱۸] به‌عنوان ابزاری برای گشودن این برهم‌نهی و استخراج مؤلفه‌هایی نسبتاً تک‌معنا[۱۹] از فضای فعال‌سازی مدل‌های زبانی معرفی شده‌اند [۴، ۶]، و تاکنون عمدتاً برای اهداف تحلیلی و تفسیرپذیری[۲۰] مورد استفاده قرار گرفته‌اند: یعنی برای فهمیدن آنچه یک مدل از پیش

[10] Back-translation
[11] Paraphrase
[12] Paraphrase Identification
[13] Fine-tuning
[14] Language Modeling
[15] Contrastive Loss
[16] Latent Space
[17] Superposition
[18] Sparse Autoencoders, SAE
[19] Monosemantic
[20] Interpretability

آموزش‌دیده «می‌داند»، نه برای تغییردادن آنچه مدل می‌آموزد.

ایدهٔ محوری این پایان‌نامه، جابه‌جایی نقش خودرمزگذار پراکنده از یک ابزار صرفاً تحلیلی به یک فضای هدف برای آموزش است: به‌جای اعمال تابع هزینهٔ ناوردایی[۲۱] مستقیماً بر فضای خام مدل، این تابع هزینه بر روی کدهای نهان حاصل از عبوردادن فعال‌سازی‌های مدل از یک خودرمزگذار پراکندهٔ از پیش‌آموزش‌دیده و ثابت[۲۲] اعمال می‌شود. از آنجا که این خودرمزگذار، بازنمایی خام را به مجموعه‌ای پراکنده‌تر و به‌طور نسبی مجزاتر از ویژگی‌ها[۲۳] تجزیه می‌کند، این پایان‌نامه این فرضیه را می‌آزماید که نزدیک‌کردن جفت‌جمله‌های هم‌معنی به هم و دورکردن جفت‌جمله‌های ناهم‌معنی از هم، در این فضای پراکنده، مؤثرتر و «تمیزتر» از انجام همان کار در فضای خام مدل باشد.

۲.۱ بیان مسئله

مسئلهٔ این پژوهش را می‌توان در سه پرسش پژوهشی صورت‌بندی کرد:

۱. آیا اعمال یک تابع هزینهٔ ناوردایی-که جفت‌جمله‌های هم‌معنی PAWS را نزدیک و جفت‌جمله‌های ناهم‌معنی را دور از هم نگاه می‌دارد-در فضای نهان یک خودرمزگذار پراکندهٔ ثابت، نسبت به اعمال همان تابع هزینه در فضای خام جریان باقیمانده، جداسازی بهتری میان جفت‌های هم‌معنی و ناهم‌معنی تولید می‌کند؟

۲. این جداسازی چگونه به انتخاب لایه(های) هدف در عمق مدل و به وزن نسبی تابع هزینهٔ ناوردایی در برابر تابع هزینهٔ زبانی وابسته است؟

۳. ریزتنظیم‌کردن مدل در جهت این هدف، با چه هزینه‌ای-از نظر افت کیفیت زبان‌مدل‌سازی و از نظر اعتبار خود خودرمزگذار-همراه است، و آیا می‌توان این هزینه را با یک منظم‌ساز صریح مهار کرد؟

پرسش سوم از این جهت اهمیت دارد که کل رویکرد پیشنهادی به یک فرض ضمنی متکی است: اینکه خودرمزگذار پراکندهٔ ثابت، در طول ریزتنظیم مدل زبانی، همچنان بازسازی‌کنندهٔ باکیفیتی از فعال‌سازی‌های مدل باقی بماند. اگر فعال‌سازی‌های مدل، در پی ریزتنظیم، از ناحیه‌ای که خودرمزگذار روی آن آموزش دیده دور شوند، سنجه‌هایی که در فضای این خودرمزگذار محاسبه می‌شوند (از جمله همان سنجهٔ جداسازی هم‌معنی/ناهم‌معنی

[21] Invariance Loss
[22] Frozen
[23] Features

که هدف اصلی این پژوهش است) دیگر قابل اعتماد نخواهند بود، چرا که آنچه اندازه‌گیری می‌شود، بازتابی از یک ابزار سنجش نامنطبق خواهد بود، نه بازتابی از تغییر واقعی در بازنمایی مدل. به همین دلیل، این پژوهش از ابتدا یک جزء منظم‌ساز بازسازی[۲۴] را نیز در تابع هزینهٔ کلی گنجانده است تا اعتبار خودرمزگذار، در طول آموزش و پایش حفظ شود.

۳.۱ هدف تحقیق

هدف اصلی این پایان‌نامه، طراحی و ارزیابی تجربی روشی برای ریزتنظیم کارآمد پارامتر[۲۵] یک مدل زبانی از پیش‌آموزش‌دیده است، به‌گونه‌ای که بازنمایی جفت‌جمله‌های هم‌معنی و ناهم‌معنی-آن‌گونه که در مجموعه‌دادهٔ PAWS تعریف شده‌اند-در فضای نهان یک خودرمزگذار پراکندهٔ ثابت، از یکدیگر بهتر متمایز شوند. این هدف کلی به اهداف فرعی زیر تجزیه می‌شود:

- طراحی یک تابع هزینهٔ ترکیبی که هزینهٔ زبان‌مدل‌سازی روی یک پیکرهٔ عمومی (برای حفظ سلامت زبانی مدل)، هزینهٔ ناوردایی روی جفت‌جمله‌های PAWS (برای شکل‌دادن به بازنمایی)، و منظم‌ساز بازسازی خودرمزگذار (برای حفظ اعتبار) را همزمان بهینه کند.

- مقایسهٔ تجربی اعمال تابع هزینهٔ ناوردایی در فضای خام در برابر فضای نهان خودرمزگذار، تحت شرایط کنترل‌شدهٔ یکسان.

- بررسی حساسیت نتایج به دو ابرپارامتر کلیدی: لایهٔ (یا لایه‌های) هدف اعمال تابع هزینهٔ ناوردایی، و وزن نسبی این تابع هزینه.

- تحلیل اثرات جانبی این ریزتنظیم-از جمله میزان تعمیم‌پذیری بهبود به لایه‌های غیرهدف، تأثیر آن بر سرگشتگی[۲۶] مدل روی متن عمومی، و پایداری کیفیت بازسازی خودرمزگذار در طول آموزش.

[24] Reconstruction Regularizer
[25] Parameter-Efficient Fine-Tuning
[26] Perplexity

۴.۱ روش انجام تحقیق (خلاصه)

این پژوهش از نوع تجربی[۲۷] و کاربردی است. مدل زبانی Pythia-70m-deduped [۱] به همراه یک تطبیق‌دهندهٔ کم‌رتبه[۲۸] [۱۵] به‌عنوان مدل پایه انتخاب شد. برای هر لایه از این مدل، از یک خودرمزگذار پراکندهٔ از پیش‌آموزش‌دیده و منتشرشدهٔ عمومی-بارگذاری‌شده از طریق کتابخانهٔ SAELens [۳]-استفاده شده که در طول کل فرایند ریزتنظیم، ثابت (منجمد) نگه داشته می‌شود. جفت‌جمله‌های هم‌معنی و ناهم‌معنی مجموعه‌دادهٔ PAWS [۳۳] منبع سیگنال نظارتی برای تابع هزینهٔ ناوردایی هستند، و بخشی از پیکرهٔ WikiText-2 برای حفظ سلامت زبان‌مدل‌سازی مدل در کنار آن به کار می‌رود. چهار شرط آزمایشی متفاوت (از حالتی که هیچ تابع هزینهٔ ناوردایی‌ای اعمال نمی‌شود، تا حالت‌هایی که این تابع هزینه در فضای خام یا فضای خودرمزگذار، با یا بدون یک جزء تکمیلی حمایتی، اعمال می‌شود) در برابر پنج مقدار برای وزن تابع هزینهٔ ناوردایی و ده حالت متفاوت برای انتخاب لایهٔ هدف (شامل تک‌لایه‌ها و ترکیب چند لایهٔ همزمان) به‌صورت آزمایش‌های شبکه‌ای[۲۹] سیستماتیک اجرا و ارزیابی شده‌اند. جزئیات کامل این روش، موضوع فصل سوم است.

۵.۱ نوآوری و اهمیت پژوهش

تا آنجا که در چارچوب این پایان‌نامه بررسی شده، بیشتر کاربردهای موجود خودرمزگذارهای پراکنده در ادبیات تفسیرپذیری مکانیستی[۳۰]، یا برای کشف و نام‌گذاری پس‌ازآموزش ویژگی‌های یک مدل ثابت به کار رفته‌اند [۴، ۲۷]، یا برای هدایت[۳۱] رفتار مدل در زمان استنتاج[۳۲] با دخالت مستقیم در مقدار یک ویژگی از پیش‌شناسایی‌شده [۲۸، ۲۷]. نوآوری این پایان‌نامه در آن است که خودرمزگذار پراکنده را نه به‌عنوان ابزار تحلیل پس‌ازآموزش و نه به‌عنوان اهرم دستکاری زمان استنتاج، بلکه به‌عنوان فضای هدف یک تابع هزینه در حین آموزش به کار می‌گیرد؛ به بیان دیگر، خودرمزگذار در این طرح، نقش یک عدسی ثابت را ایفا می‌کند که از میان آن، سیگنال گرادیانی حاصل از یک وظیفهٔ نظارت‌شده (تشخیص هم‌معنی‌بودن) به پارامترهای مدل زبانی بازمی‌گردد.

سهم دیگر این پژوهش، ارائهٔ یک منظم‌ساز صریح برای حفظ اعتبار خودرمزگذار در حین این نوع آموزش است؛ نکته‌ای که در کاربردهای رایج (کشف پس‌ازآموزش) اساساً محل بحث نیست، چرا که در آن‌ها مدل زبانی

[27] Empirical
[28] LoRA, Low-Rank Adaptation
[29] Grid Search
[30] Mechanistic Interpretability
[31] Steering
[32] Inference

حین تحلیل تغییر نمی‌کند. سرانجام، این پژوهش با انجام یک مطالعهٔ حذفی[۳۳] نسبتاً گسترده-در دو بُعد عمق لایه و وزن تابع هزینه، و در برابر یک شرط کنترلی فاقد هرگونه تابع هزینهٔ ناوردایی-تصویری تجربی از سازوکارها، محدودیت‌ها و مصالحه‌های[۳۴] این رویکرد به دست می‌دهد که می‌تواند مبنایی برای پژوهش‌های آتی روی مدل‌ها و مجموعه‌داده‌های بزرگ‌تر باشد.

۶.۱ تعریف واژه‌های کلیدی

برای روشن‌شدن ادامهٔ متن، برخی از مهم‌ترین اصطلاحاتی که در این پایان‌نامه به‌کرّات استفاده می‌شوند، در این‌جا به‌اختصار معرفی می‌شوند؛ تعریف کامل‌تر و فنی‌تر هر یک، در فصل‌های دوم و سوم ارائه خواهد شد.

بازنویسی[۳۵]: دو جمله که با وجود تفاوت در واژگان یا ساختار سطحی، معنای یکسان یا تقریباً یکسانی را منتقل می‌کنند.

جریان باقیمانده[۳۶]: مسیر برداری اصلی‌ای که در معماری ترنسفورمر از ورودی تا خروجی شبکه امتداد دارد و هر لایه، خروجی خود را به‌صورت جمعی به آن می‌افزاید.

خودرمزگذار پراکنده (SAE)[۳۷]: شبکه‌ای کوچک که یک بردار فعال‌سازی را به فضایی با ابعاد بسیار بیشتر ولی با فعالیت پراکنده (اکثر مؤلفه‌ها صفر) می‌برد و سپس تلاش می‌کند از روی همان کد پراکنده، بردار اصلی را بازسازی کند؛ در این پایان‌نامه، این شبکه از پیش آموزش دیده و در حین ریزتنظیم مدل زبانی، ثابت نگه داشته می‌شود.

تابع هزینهٔ ناوردایی[۳۸]: جزئی از تابع هزینهٔ کلی که بازنمایی جفت‌جمله‌های هم‌معنی را به هم نزدیک و بازنمایی جفت‌جمله‌های ناهم‌معنی را از هم دور نگاه می‌دارد.

لورا (LoRA)[۳۹]: روشی برای ریزتنظیم کارآمد پارامتر که به‌جای به‌روزرسانی مستقیم کل ماتریس‌های وزن مدل، یک به‌روزرسانی کم‌رتبه به آن‌ها می‌افزاید و تنها همین بخش کوچک را آموزش می‌دهد.

AUROC: سطح زیر منحنی مشخصهٔ عملکرد گیرنده[۴۰]، سنجه‌ای بین صفر تا یک برای کیفیت تفکیک دو دسته (در اینجا: جفت‌های هم‌معنی در برابر ناهم‌معنی) بر اساس یک سنجهٔ پیوسته (در اینجا: فاصلهٔ کسینوسی)؛ مقدار ۰٫۵ برابر با حدس تصادفی و مقدار ۱ برابر با تفکیک کامل است [۱۰].

[33] Ablation Study
[34] Trade-offs
[40] Receiver Operating Characteristic

۷.۱ ساختار پایان‌نامه

باقی این پایان‌نامه در چهار فصل سازمان‌دهی شده است. فصل دوم مروری بر ادبیات موضوع را در چهار محور اصلی ارائه می‌دهد: بازنمایی و شباهت معنایی در مدل‌های زبانی، یادگیری تقابلی، تفسیرپذیری مکانیستی و خودرمزگذارهای پراکنده، و ریزتنظیم کارآمد پارامتر و حفظ رفتار مدل در حین آن. فصل سوم روش پیشنهادی-معماری، تابع هزینه، شرایط آزمایشی و طرح آزمایش‌های شبکه‌ای-را با جزئیات کامل شرح می‌دهد. فصل چهارم نتایج تجربی حاصل از این آزمایش‌ها را، به همراه تحلیل و نمودارهای مرتبط، ارائه می‌کند. فصل پنجم پایان‌نامه را با جمع‌بندی یافته‌ها، بیان محدودیت‌ها و پیشنهادهایی برای پژوهش‌های آینده به پایان می‌برد.

فصل ۲

مروری بر ادبیات موضوع

۱.۲ مقدمه

این پایان‌نامه در تقاطع چهار حوزهٔ پژوهشی قرار دارد که تا پیش از این، عمدتاً به‌طور مستقل از یکدیگر پیش رفته‌اند: (۱) بازنمایی معنا و سنجش شباهت معنایی در مدل‌های زبانی، (۲) یادگیری تقابلی به‌عنوان چارچوبی برای شکل‌دادن به فضاهای بازنمایی، (۳) تفسیرپذیری مکانیستی و به‌طور خاص خودرمزگذارهای پراکنده به‌عنوان ابزار گشودن برهم‌نهی ویژگی‌ها، و (۴) ریزتنظیم کارآمد پارامتر و روش‌های حفظ رفتار مدل در حین آن. این فصل هر یک از این چهار حوزه را به‌ترتیب و با تمرکز بر آن دسته از پژوهش‌هایی مرور می‌کند که مستقیماً پایه‌های مفهومی، روش‌شناختی یا فنی فصل سوم را می‌سازند، و در پایان (بخش ۷.۲) نشان می‌دهد این پایان‌نامه دقیقاً در کدام نقطهٔ تلاقی این خطوط پژوهشی جای می‌گیرد و چه شکافی را هدف قرار داده است.

۲.۲ بازنمایی و شباهت معنایی در مدل‌های زبانی

۱.۲.۲ از بازنمایی‌های ایستا تا بازنمایی‌های بافتاری

پیش از ظهور معماری ترنسفورمر، رایج‌ترین رویکرد برای بازنمایی معنای واژه‌ها، آموختن یک بردار ایستا[1] برای هر واژه بود که مستقل از بافت جمله، ثابت می‌ماند؛ روش word2vec [۲۱] نمونهٔ برجستهٔ این رویکرد

[1] Static

است که با پیش‌بینی واژه‌های همسایه در یک پنجرهٔ متنی (یا برعکس، پیش‌بینی یک واژه از روی همسایگانش)، بردارهایی می‌آموزد که روابط معنایی ساده-مانند قیاس‌های معنایی که با عملیات برداری ساده (جمع و تفریق) قابل‌بازتولیدند-را تا حدی در هندسهٔ فضای برداری بازتاب می‌دهند. محدودیت اصلی این رویکرد، ناتوانی در نمایش چندمعنایی[۲] و وابستگی به بافت بود: یک واژهٔ یکسان، در جمله‌های مختلف، معنای متفاوتی می‌تواند داشته باشد (برای نمونه، یک واژه که هم به‌معنای عضوی از بدن و هم به‌معنای یک ابزار به کار می‌رود)، اما بازنمایی ایستا-چون تنها یک بردار برای هر واژه در نظر می‌گیرد، صرف‌نظر از جمله‌ای که آن واژه در آن ظاهر شده-این تفاوت را نادیده می‌گیرد و ناچار میانگینی از تمام معانی ممکن آن واژه را در یک بردار فشرده می‌کند.

معرفی معماری ترنسفورمر [۳۰] و مدل‌های پیش‌آموزش‌دیدهٔ مبتنی بر آن-به‌ویژه BERT [۷] در سمت رمزگذارهای دوسویه و معماری‌های رمزگشا–محور یک‌سویه در سمت دیگر-این محدودیت را با تولید بازنمایی‌هایی بافتاری[۳] برطرف کرد: بازنمایی هر واژه، تابعی از کل جمله‌ای (یا در مورد مدل‌های یک‌سویه، کل متن پیش از آن) است که در آن ظاهر شده است. مکانیسم توجه[۴]-هستهٔ محاسباتی ترنسفورمر-این بازنمایی‌های بافتاری را با اجازه‌دادن به هر موقعیت برای «توجه‌کردن» با وزن‌های متفاوت به تمام موقعیت‌های دیگر دنباله می‌سازد؛ این وزن‌ها خود از حاصل‌ضرب داخلی بردارهای «پرسمان» و «کلید» هر موقعیت به دست می‌آیند و بنابراین، برخلاف بازنمایی ایستا، در هر پیش‌روی مجدداً و بر اساس محتوای خاص همان جمله محاسبه می‌شوند. در معماری رمزگشا-که پایهٔ مدل‌های این پایان‌نامه نیز هست-خروجی هر لایه (چه بلوک توجه و چه بلوک پیش‌خور) به‌صورت جمعی، به یک مسیر برداری مشترک موسوم به جریان باقیمانده[۵] افزوده می‌شود؛ به بیان دیگر، بازنمایی نهایی یک نشانه در عمق لایهٔ ℓ، جمع تعبیهٔ اولیهٔ آن نشانه با خروجی تک‌تک لایه‌های پیش از ℓ است. همین جریان باقیمانده است که در سرتاسر این پایان‌نامه به‌عنوان محل استخراج بازنمایی جمله در نظر گرفته شده است، و ماهیت جمعی و انباشتی آن-هر لایه، چیزی به بازنمایی قبلی می‌افزاید، نه آنکه آن را از نو بسازد-در بخش ۱.۵.۲ اهمیت ویژه‌ای پیدا می‌کند.

با این‌همه، بافتاری‌بودن بازنمایی، به‌خودی‌خود تضمینی برای معناداری آن نیست. مدل‌های زبانی بزرگ عمدتاً با هدف پیش‌بینی نشانهٔ بعدی آموزش می‌بینند، هدفی که لزوماً بازنمایی سطح جمله را در جهت سنجه‌های معنایی موردنظر انسان (مانند هم‌ارزی معنایی یا استلزام منطقی) شکل نمی‌دهد؛ بازنمایی حاصل، هر آنچه برای پیش‌بینی آماری واژهٔ بعدی مفید باشد را رمزگذاری می‌کند، که ممکن است شامل نشانه‌های سطحی و آماری زبان (مانند همایندی واژگانی) به همان اندازه‌ای باشد که شامل معنای عمیق‌تر است، بی‌آنکه مدل ابزاری برای تفکیک این دو داشته باشد. این شکاف، انگیزهٔ اصلی خط پژوهشی بعدی است.

[2] Polysemy
[3] Contextual
[4] Attention
[5] Residual Stream

۲.۲.۲ شفافیت پژوهشی خانوادهٔ مدل پایه

از آنجا که این پایان‌نامه از یک مدل رمزگشا-محور[۶] خاص (Pythia) استفاده می‌کند، مروری کوتاه بر انگیزهٔ این انتخاب، مفید است. معماری رمزگشا-فقط-که در آن مدل تنها بر پایهٔ متن پیشین، نشانهٔ بعدی را پیش‌بینی می‌کند-امروزه غالب‌ترین انتخاب برای مدل‌های زبانی عام‌منظوره است، چرا که با تولید متن سازگارتر از معماری دوسویهٔ BERT است. خانوادهٔ Pythia [۱]-مدل پایهٔ این پایان‌نامه-از میان گزینه‌های موجود در این خانواده، به‌طور خاص با هدف شفافیت پژوهشی طراحی شده است: تمام نقاط بازرسی میانی پیش‌آموزش (نه فقط چک‌پوینت نهایی)، ترتیب دقیق دادهٔ دیده‌شده در هر مرحله، و کد کامل پیش‌آموزش، به‌صورت عمومی منتشر شده‌اند. همین فلسفهٔ باز، زمینه‌ساز پیدایش اکوسیستمی از ابزارهای تحلیلی-از جمله همان خودرمزگذارهای پراکندهٔ از پیش‌آموزش‌دیده‌ای که این پایان‌نامه مستقیماً از آن‌ها استفاده می‌کند (بخش ۵.۳)-حول این خانواده از مدل‌ها شده است؛ بدون وجود چنین خودرمزگذارهایی به‌صورت آماده و عمومی، روش پیشنهادی این پایان‌نامه به آموزش از پیش یک خودرمزگذار اختصاصی نیاز می‌داشت، مرحله‌ای که خود می‌توانست منبع نامعینی اضافی-مستقل از پرسش اصلی پژوهش-باشد. کوچکی اعضای این خانواده نیز، همان‌طور که در بخش ۳.۳ اشاره خواهد شد، اجرای شبکهٔ آزمایشی گستردهٔ این پژوهش را در محدودهٔ منابع محاسباتی در دسترس ممکن ساخت.

۳.۲ تشخیص بازنویسی و سنجش شباهت معنایی متن

تشخیص بازنویسی[۷] و سنجش شباهت معنایی متن[۸] دو وظیفهٔ کلاسیک در پردازش زبان طبیعی‌اند که مستقیماً همین شکاف را می‌آزمایند: در وظیفهٔ نخست، از مدل خواسته می‌شود دو جمله را به‌عنوان بازنویسی یکدیگر یا نه، طبقه‌بندی کند؛ در وظیفهٔ دوم، از مدل خواسته می‌شود یک امتیاز پیوستهٔ شباهت (معمولاً در بازهٔ صفر تا پنج) به هر جفت‌جمله نسبت دهد. رویکرد رایج برای استخراج بازنمایی قابل‌مقایسه از یک جملهٔ کامل-به‌جای یک واژهٔ منفرد-استفاده از معماری دوقلو[۹] است، که در آن دو شبکه با وزن‌های مشترک، دو جمله را به‌طور مستقل به دو بردار می‌برند و سپس شباهت این دو بردار (معمولاً با شباهت کسینوسی) سنجیده می‌شود. Sentence-BERT [۲۵] نمونهٔ شناخته‌شدهٔ این رویکرد است که با ریزتنظیم BERT در یک ساختار دوقلو و بر روی جفت‌جمله‌های برچسب‌خورده، بازنمایی‌هایی می‌آموزد که شباهت کسینوسی‌شان-بدون نیاز به عبور هر دو جمله از مدل به‌طور هم‌زمان، برخلاف رویکرد متقاطع اصلی BERT-با شباهت معنایی مورد نظر انسان

[6] Decoder-only
[7] Paraphrase Identification
[8] Semantic Textual Similarity, STS
[9] Siamese

هم‌بستگی بالایی داشته باشد؛ این جدایی محاسباتی (رمزگذاری مستقل هر جمله) همچنین پیش‌نیاز فنی رویکردی است که این پایان‌نامه نیز از آن استفاده می‌کند، چرا که در آن نیز هر جمله از یک جفت، به‌طور مستقل از مدل عبور داده می‌شود.

SimCSE [۱۳] گامی فراتر برداشت و نشان داد حتی بدون برچسب انسانی، صرف عبوردادن یک جمله دو بار از مدل با دو دراپ‌اوت تصادفی متفاوت-و در نظرگرفتن این دو خروجی اندکی متفاوت به‌عنوان یک جفت مثبت در یک تابع هزینهٔ تقابلی (بخش ۴.۲)-به‌تنهایی بازنمایی‌های جمله‌ای به‌مراتب بهتری نسبت به بازنمایی‌های خام BERT تولید می‌کند؛ در نسخهٔ نظارت‌شدهٔ همین کار، جفت‌های استلزام منطقی برچسب‌خورده به‌عنوان جفت مثبت و جفت‌های تناقض به‌عنوان جفت منفی سخت به کار رفته‌اند. این یافته، اهمیت صورت‌بندی تابع هزینه (نه صرفاً معماری یا حجم داده) را برای کیفیت بازنمایی جمله برجسته می‌کند-نکته‌ای که مستقیماً به رویکرد این پایان‌نامه (طراحی یک تابع هزینهٔ تقابلی/ناوردا، هرچند نه برای آموزش از پایه بلکه برای شکل‌دادن دوبارهٔ بازنمایی یک مدل از پیش‌آموزش‌دیده) مرتبط است.

۱.۳.۲ PAWS و شکاف میان شباهت لفظی و معنایی

روش‌هایی مانند SBERT و SimCSE عمدتاً بر روی مجموعه‌داده‌هایی نظیر STS ارزیابی می‌شوند که در آن‌ها شباهت لفظی و شباهت معنایی معمولاً هم‌جهت‌اند: جملاتی که واژگان مشترک کمی دارند، معمولاً از نظر معنایی نیز کم‌شباهت‌اند، و برعکس. این هم‌بستگی، یک راه میان‌بُر بالقوه برای مدل فراهم می‌کند: مدلی که صرفاً همپوشانی واژگانی یا حتی ترتیب کیسه‌ای[۱۰] واژه‌ها را می‌سنجد، می‌تواند بدون فهم واقعی ساختار نحوی یا معنایی، عملکرد نسبتاً خوبی روی چنین مجموعه‌داده‌هایی کسب کند.

مجموعه‌دادهٔ PAWS [۳۳] دقیقاً برای شکستن همین هم‌بستگی طراحی شد. روش ساخت آن دو مرحله دارد: نخست، با جابه‌جایی ترتیب کلمات یک جملهٔ اصلی (به‌گونه‌ای که ساختار دستوری حاصل هنوز قابل‌قبول باشد)، جمله‌های جدیدی تولید می‌شود که همپوشانی واژگانی بسیار بالایی با جملهٔ اصلی دارند اما بسته به اینکه کدام کلمات جابه‌جا شده‌اند، معنای یکسان یا کاملاً متفاوتی می‌توانند داشته باشند (برای نمونه، جابه‌جایی نقش فاعل و مفعول در یک جمله، معنا را کاملاً تغییر می‌دهد، درحالی‌که جابه‌جایی یک قید زمانی ممکن است معنا را دست‌نخورده باقی بگذارد)؛ دوم، همین فرایند با ترجمهٔ رفت‌وبرگشتی[۱۱] (ترجمهٔ جمله به زبانی دیگر و بازگرداندن آن به زبان اصلی) تکرار می‌شود تا تنوع ساختاری بیشتری حاصل شود. برچسب نهایی هر جفت (هم‌معنی/ناهم‌معنی) توسط ارزیاب‌های انسانی تعیین شده است. نتیجه، مجموعه‌ای از جفت‌جمله‌هاست که

[10] Bag-of-words
[11] Back-translation

در آن‌ها، برخلاف STS، همپوشانی واژگانی بالا دیگر نشانهٔ قابل‌اتکایی برای هم‌معنی‌بودن نیست.

نویسندگان PAWS نشان دادند مدل‌های زمان خود-از جمله مدل‌هایی مبتنی بر BERT که با رویکردهای بالا آموزش دیده بودند و روی مجموعه‌داده‌های متعارف تشخیص بازنویسی به دقت بالایی می‌رسیدند-در تشخیص این جفت‌های دشوار به‌شدت افت می‌کنند [۳۳]، و نسخهٔ چندزبانهٔ آن، PAWS-X [۳۲]، نشان داد این ضعف به زبان انگلیسی هم محدود نیست. این مجموعه‌داده-که مبنای مستقیم روش پیشنهادی این پایان‌نامه است-بنابراین نه صرفاً یک مجموعه‌دادهٔ تشخیص بازنویسی دیگر، بلکه ابزاری تشخیصی برای آزمودن این فرضیه است که آیا بازنمایی یک مدل، واقعاً بر پایهٔ معنا شکل گرفته یا بر پایهٔ همپوشانی سطحی؛ همین ویژگی است که آن را به گزینه‌ای طبیعی برای سنجش کیفیت بازنمایی لایه‌های میانی یک مدل زبانی-موضوع فصل سوم و چهارم این پایان‌نامه-تبدیل می‌کند.

۲.۳.۲ سنجش جداسازی: از دقت طبقه‌بندی تا سطح زیر منحنی

نکتهٔ روش‌شناختی دیگری که در مرور ادبیات تشخیص بازنویسی اهمیت دارد، چگونگی سنجش کیفیت جداسازی است. بسیاری از کارهای اولیه در این حوزه، مسئله را به‌صورت یک وظیفهٔ طبقه‌بندی دودویی کامل صورت‌بندی می‌کنند: یک طبقه‌بندی‌کننده (اغلب یک لایهٔ خطی کوچک روی بازنمایی جفت‌جمله) آموزش داده می‌شود تا برچسب هم‌معنی/ناهم‌معنی را پیش‌بینی کند، و سنجهٔ گزارش‌شده، دقت این طبقه‌بندی‌کننده روی دادهٔ آزمون است. چنین رویکردی، برای هدف این پایان‌نامه دو محدودیت دارد: نخست، به یک مرحلهٔ آموزش جداگانه (آموزش طبقه‌بندی‌کننده) نیاز دارد که خود می‌تواند منبع نویز یا بیش‌برازش باشد، به‌ویژه وقتی هدف، مقایسهٔ ۱۶۰ پیکربندی متفاوت است و آموزش یک طبقه‌بندی‌کنندهٔ جداگانه برای هر پیکربندی، هم هزینهٔ محاسباتی و هم منبع ناهمگونی آماری اضافه می‌کند؛ دوم، دقت طبقه‌بندی، خود به یک آستانهٔ تصمیم دلخواه وابسته است که انتخاب آن می‌تواند نتیجه را تحت‌تأثیر قرار دهد.

به همین دلیل، این پایان‌نامه (همسو با رویکردی که در بسیاری از کارهای سنجش کیفیت بازنمایی جمله، از جمله نسخه‌های اولیهٔ STS و کارهایی مانند Sentence-BERT [۲۵] که شباهت کسینوسی خام را مستقیماً با سنجه‌های هم‌بستگی می‌سنجند، رایج است) به‌جای دقت طبقه‌بندی، از سطح زیر منحنی مشخصهٔ عملکرد گیرنده (AUROC) [۱۰] استفاده می‌کند: با در نظرگرفتن فاصلهٔ کسینوسی هر جفت به‌عنوان یک سنجهٔ پیوستهٔ «امتیاز ناهم‌معنی‌بودن»، بدون آموزش هیچ طبقه‌بندی‌کنندهٔ اضافی و بدون انتخاب هیچ آستانه‌ای، می‌توان کیفیت جداسازی دو توزیع (فاصلهٔ جفت‌های هم‌معنی در برابر فاصلهٔ جفت‌های ناهم‌معنی) را مستقیماً از روی خود بازنمایی سنجید.

یک ویژگی آماری مفید AUROC که سنجه‌های مبتنی بر دقت فاقد آن‌اند، تفسیر احتمالاتی مستقیم آن

است: مقدار AUROC دقیقاً برابر است با احتمال آنکه، در یک انتخاب تصادفی یک جفت هم‌معنی و یک جفت ناهم‌معنی، فاصلهٔ جفت ناهم‌معنی بزرگ‌تر از فاصلهٔ جفت هم‌معنی باشد. این تفسیر، مقایسهٔ مستقیم نتایج در سرتاسر شبکهٔ آزمایشی این پایان‌نامه-که در آن، لایه‌های مختلف، دامنه‌های مطلقاً متفاوتی برای فاصلهٔ کسینوسی دارند-را بدون نیاز به نرمال‌سازی دستی این دامنه‌ها ممکن می‌سازد؛ ویژگی‌ای که برای طرح آزمایش سه‌بُعدی فصل سوم (شرط × λ × لایه) اهمیت عملی مستقیم دارد.

۴.۲ یادگیری تقابلی

۱.۴.۲ مبانی و صورت‌بندی کلی

یادگیری تقابلی[12] چارچوبی است برای آموختن یک فضای بازنمایی که در آن، نمونه‌های «مشابه» (جفت‌های مثبت) به هم نزدیک و نمونه‌های «نامشابه» (جفت‌های منفی) از هم دور نگاه داشته می‌شوند، بدون آنکه لزوماً برچسب کلاس صریحی در کار باشد. ریشهٔ این ایده به کارهایی مانند FaceNet [۲۶] در بازشناسی چهره بازمی‌گردد، که با یک تابع هزینهٔ سه‌تایی[13] بر روی سه‌تایی‌های (x_a, x_p, x_n) (به‌ترتیب: لنگر، مثبت، منفی) به شکل $\max(۰,\ d(x_a, x_p) - d(x_a, x_n) + m)$ عمل می‌کند-یعنی فاصلهٔ لنگر تا نمونهٔ مثبت را دست‌کم به‌اندازهٔ یک حاشیهٔ[14] ثابت m کمتر از فاصلهٔ لنگر تا نمونهٔ منفی نگاه می‌دارد-بازنمایی چهره‌ها را چنان می‌آموزد که فاصلهٔ اقلیدسی مستقیماً معیار شباهت هویت باشد. تابع هزینهٔ ناوردایی این پایان‌نامه (بخش ۶.۳) نیز، از نظر ساختاری، بر پایهٔ همین ایده-مقایسهٔ فاصلهٔ جفت «مثبت» با فاصلهٔ جفت «منفی»-بنا شده، هرچند به‌جای یک حاشیهٔ ثابت و دستی، از یک مقیاس و بایاس آموختنی در دل یک تابع هزینهٔ آنتروپی متقاطع دودویی استفاده می‌کند.

صورت‌بندی متداول‌تر امروزی، مبتنی بر تابع هزینهٔ InfoNCE [۲۹] است:

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(x_a, x_p)/\tau)}{\exp(\text{sim}(x_a, x_p)/\tau) + \sum_{k=۱}^{K} \exp(\text{sim}(x_a, x_n^{(k)})/\tau)} \qquad (۱.۲)$$

که در آن یک جفت مثبت را در برابر K نمونهٔ منفی (نه فقط یکی) قرار می‌دهد و آن را به‌صورت یک وظیفهٔ

[12] Contrastive Learning
[13] Triplet Loss
[14] Margin

طبقه‌بندی softmax صورت‌بندی می‌کند؛ پارامتر دما[15]ی τ تندی توزیع حاصل را کنترل می‌کند: مقدار کوچک τ، تابع هزینه را بیشتر متمرکز بر سخت‌ترین نمونه‌های منفی (آن‌هایی که شباهت بالایی با لنگر دارند) می‌کند، درحالی‌که مقدار بزرگ‌تر آن، وزن یکنواخت‌تری به تمام نمونه‌های منفی می‌دهد؛ این پارامتر، در عمل، نقشی مشابه ضریب مقیاس آموختنی γ در تابع هزینهٔ این پایان‌نامه (بخش ۶.۳) ایفا می‌کند، با این تفاوت که در InfoNCE معمولاً τ یک ابرپارامتر ثابت و از پیش‌تعیین‌شده است، درحالی‌که در این پایان‌نامه، مقیاس متناظر، خود در حین آموزش یاد گرفته می‌شود. SimCLR [۵] در حوزهٔ بینایی ماشین (با استفاده از دو تبدیل تصادفی متفاوت از یک تصویر به‌عنوان جفت مثبت) و Supervised Contrastive Learning [۱۷] (که برچسب کلاس را برای تعیین جفت‌های مثبت/منفی به کار می‌گیرد، به‌جای تکیه بر تبدیل‌های خودکار) نمونه‌های شناخته‌شدهٔ این رویکردند.

۲.۴.۲ انتخاب نمونه‌های منفی و نقش نمونه‌های منفی سخت

کیفیت فضای بازنمایی حاصل از یادگیری تقابلی، به‌شدت به چگونگی انتخاب نمونه‌های منفی وابسته است. اگر نمونه‌های منفی به‌سادگی از هر نقطهٔ دیگر فضای داده انتخاب شوند، مدل می‌تواند به‌سرعت یاد بگیرد آن‌ها را با نشانه‌های سطحی و آسان (برای نمونه، طول جمله یا موضوع کلی) از نمونهٔ لنگر تفکیک کند، بدون آنکه مجبور شود به تفاوت‌های ظریف‌تر توجه کند؛ این پدیده در ادبیات با عنوان فروپاشی نمونه‌های منفی آسان[16] شناخته می‌شود. برای مقابله با آن، بسیاری از کارها بر اهمیت نمونه‌های منفی سخت[17]-نمونه‌هایی که از نظر سطحی به نمونهٔ لنگر شبیه‌اند اما از نظر برچسب هدف، متفاوت‌اند-تأکید کرده‌اند؛ برای نمونه، نسخهٔ نظارت‌شدهٔ SimCSE [۱۳] به‌طور صریح از جفت‌های تناقض منطقی (که از نظر موضوع و واژگان به جملهٔ لنگر نزدیک‌اند اما معنایی متضاد دارند) به‌عنوان نمونهٔ منفی سخت استفاده می‌کند.

از این زاویه، مجموعه‌دادهٔ PAWS را می‌توان نه صرفاً یک مجموعه‌دادهٔ ارزیابی، بلکه یک منبع طبیعی و از پیش‌آماده از نمونه‌های منفی سخت (جفت‌های ناهم‌معنی با همپوشانی واژگانی بسیار بالا) دانست؛ این دقیقاً همان ویژگی‌ای است که این پایان‌نامه از آن برای ساختن جزء «دافعه‌ای»[18] تابع هزینهٔ ناوردایی (بخش ۶.۳) بهره می‌برد. بدون چنین نمونه‌های منفی سختی، تابع هزینهٔ ناوردایی می‌توانست به‌سادگی با فاصله‌گرفتن کلی بازنمایی هر دو جمله از یکدیگر (صرف‌نظر از هم‌معنی‌بودن یا نبودن آن‌ها) کمینه شود؛ وجود جفت‌های ناهم‌معنی لفظاً مشابه، مدل را وامی‌دارد تفاوتی ظریف‌تر و معنایی‌تر بیاموزد.

[15] Temperature
[16] Easy Negative Collapse
[17] Hard Negatives
[18] Repulsive

۳.۴.۲ جایگاه این پژوهش در ادبیات یادگیری تقابلی

تابع هزینهٔ ناوردایی‌ای که در این پایان‌نامه به کار رفته، از نظر مفهومی در همین خانواده جای می‌گیرد-جفت هم‌معنی به‌عنوان جفت مثبت و جفت ناهم‌معنی به‌عنوان جفت منفی سخت-اما دو تفاوت مهم با اکثر ادبیات یادگیری تقابلی دارد. نخست، از نظر صورت‌بندی ریاضی، به‌جای یک وظیفهٔ softmax چندکلاسه (یک مثبت در برابر K منفی، مطابق InfoNCE)، از یک تابع هزینهٔ آنتروپی متقاطع دودویی با مقیاس و بایاس آموختنی استفاده شده-صورت‌بندی‌ای نزدیک‌تر به تابع هزینهٔ سه‌تایی، اما بدون حاشیهٔ دستی‌تنظیم‌شده. دوم، و مهم‌تر، تفاوت این پژوهش با اکثر ادبیات یادگیری تقابلی، غایت استفاده از این تابع هزینه است: در SimCLR، SimCSE و مشابه آن‌ها، تابع هزینهٔ تقابلی، تنها یا اصلی‌ترین سیگنال آموزشی برای ساختن یک فضای بازنمایی از پایه (یا دست‌کم، برای ریزتنظیم کامل مدل روی این هدف به‌تنهایی) است؛ در این پایان‌نامه، این تابع هزینه یک سیگنال نسبتاً کوچک و مکمل-همراه با یک هزینهٔ زبان‌مدل‌سازی موازی و یک منظم‌ساز بازسازی-است که برای شکل‌دادن دوبارهٔ بازنمایی یک مدل از پیش‌آموزش‌دیده، بدون آسیب‌زدن به توانایی‌های عمومی زبانی آن، به کار می‌رود. سومین تفاوت، که موضوع بخش بعدی است، فضایی است که این شباهت کسینوسی در آن محاسبه می‌شود: نه فضای خام بازنمایی مدل، بلکه فضای نهان یک خودرمزگذار پراکنده.

۴.۴.۲ ریسک فروپاشی بازنمایی

یک هشدار شناخته‌شده در ادبیات یادگیری تقابلی، پدیدهٔ فروپاشی بازنمایی[19] است: اگر تابع هزینه صرفاً بر نزدیک‌کردن جفت‌های مثبت متمرکز باشد، بدون هیچ قید متعادل‌کننده‌ای برای دورنگاه‌داشتن نمونه‌های نامرتبط از هم، ساده‌ترین راه‌حلی که بهینه‌سازی می‌تواند بیابد، نگاشت تمام ورودی‌ها به یک نقطهٔ ثابت واحد است-راه‌حلی که تابع هزینهٔ مثبت‌محور را دقیقاً صفر می‌کند اما بازنمایی حاصل را کاملاً بی‌فایده می‌سازد، چرا که دیگر هیچ اطلاعاتی دربارهٔ تفاوت ورودی‌ها حمل نمی‌کند. روش‌هایی مانند SimCLR [۵] و InfoNCE [۲۹] این ریسک را با گنجاندن صریح نمونه‌های منفی در همان تابع هزینه (که هرگونه نزدیکی بیش‌ازحد جفت‌های نامرتبط را جریمه می‌کند) کنترل می‌کنند؛ برخی روش‌های جدیدتر بدون نمونهٔ منفی (مانند BYOL یا SimSiam) از راهکارهای معماری جایگزین (مانند عدم‌تقارن در پس‌انتشار گرادیان میان دو شاخه) برای پیشگیری از فروپاشی استفاده می‌کنند، بدون نیاز به نمونهٔ منفی صریح.

تابع هزینهٔ ناوردایی در این پایان‌نامه (بخش ۶.۳)، از خانوادهٔ نخست است: جزء دافعه‌ای (جفت‌های ناهم‌معنی PAWS) به همان اندازهٔ جزء جاذبه‌ای، صریحاً در تابع هزینه حضور دارد. این انتخاب، از یک

[19] Representational Collapse

منظر خاص این پایان‌نامه، حتی حیاتی‌تر از نقش متعارفش در جلوگیری از فروپاشی کامل بازنمایی است: چون جفت‌های ناهم‌معنی PAWS به‌طور خاص، نمونه‌های منفی سخت هستند (بخش ۲.۴.۲)، وجودشان در تابع هزینه نه‌تنها از فروپاشی کامل بازنمایی جلوگیری می‌کند، بلکه دقیقاً همان تمایز ظریفی را که هدف اصلی این پایان‌نامه است-تفکیک هم‌معنی از ناهم‌معنی در حضور همپوشانی واژگانی بالا-به‌طور مستقیم در بهینه‌سازی می‌گنجاند؛ بدون این جزء، هیچ تضمینی وجود نداشت که تنها جزء جاذبه‌ای، به تفکیک معنایی-به‌جای فروپاشی ساده-بینجامد.

۵.۲ تفسیرپذیری مکانیستی و خودرمزگذارهای پراکنده

۱.۵.۲ برهم‌نهی و چندمعنایی

حوزهٔ تفسیرپذیری مکانیستی[۲۰] به دنبال فهم آن است که یک شبکهٔ عصبی آموزش‌دیده، محاسبات درونی خود را با چه سازوکاری انجام می‌دهد؛ نه صرفاً اینکه چه ورودی به چه خروجی می‌انجامد. Elhage و همکاران [۹] با ارائهٔ یک چارچوب ریاضی برای تحلیل مدارهای[۲۱] درونی ترنسفورمر-از جمله همین دیدگاه جمعی/انباشتی جریان باقیمانده که در بخش ۲.۲ معرفی شد-این حوزه را در بستر مدل‌های زبانی مدرن صورت‌بندی کردند.

یکی از یافته‌های مهم این خط پژوهشی، پدیدهٔ برهم‌نهی[۲۲] است. Elhage و همکاران [۸] با استفاده از مدل‌های اسباب‌بازی[۲۳] کوچک-شبکه‌هایی که مصنوعاً وادار شده‌اند تعداد معینی «ویژگی» ساختگی را در ابعادی کمتر از تعداد آن ویژگی‌ها فشرده کنند-نشان دادند وقتی تعداد مفاهیم بالقوه‌ای که یک شبکه باید نمایش دهد، از تعداد ابعاد موجود در آن لایه بیشتر باشد (وضعیتی که در مدل‌های زبانی واقعی، با میلیون‌ها مفهوم ممکن در برابر چند صد یا چند هزار بُعد، به‌شدت محتمل است)، شبکه-به‌جای تخصیص یک بُعد متعامد به هر مفهوم، که ظرفیت محدود فضا اجازه نمی‌دهد-می‌تواند با قراردادن چند مفهوم به‌صورت همپوشان (نه متعامد، بلکه با زاویه‌ای اندک نسبت به هم) در همان چند بُعد مشترک، بیش از تعداد ابعاد خود، مفهوم نمایش دهد. این راهبرد، تنها زمانی به‌صرفه است که مفاهیم مورد نظر به‌ندرت هم‌زمان فعال شوند (که در دادهٔ زبانی طبیعی، فرض معقولی است: بیشتر مفاهیم ممکن، در بیشتر جمله‌ها اصلاً حضور ندارند)، چرا که برهم‌نهی به بهای مقداری تداخل و اختلال میان مفاهیم هم‌زمان‌فعال تمام می‌شود.

[20] Mechanistic Interpretability
[21] Circuits
[22] Superposition
[23] Toy Models

نتیجهٔ مستقیم این پدیده، چندمعنایی[۲۴] است: یک نورون منفرد در شبکه، می‌تواند در واکنش به چند مفهوم کاملاً نامرتبط با هم فعال شود (برای نمونه، هم در واکنش به یک الگوی نحوی و هم در واکنش به یک موضوع محتوایی کاملاً بی‌ربط)، و همین امر، تفسیر مستقیم فعال‌سازی تک‌تک نورون‌ها را دشوار می‌سازد؛ نمی‌توان به یک نورون اشاره کرد و گفت «این نورون نمایانگر فلان مفهوم است»، چون همان نورون در بافت‌های دیگر، نمایانگر مفهومی کاملاً متفاوت است. این دقیقاً همان مشکلی است که در بخش ۲.۳ به‌عنوان دلیل پرهیز از اعمال مستقیم تابع هزینهٔ ناوردایی بر فضای خام جریان باقیمانده مطرح شد: جابه‌جاکردن یک بُعد برهم‌نهی‌شده در یک جهت-برای مثال، برای دورترکردن بازنمایی دو جملهٔ ناهم‌معنی-می‌تواند چندین مفهوم نامرتبط دیگر را که در همان بُعد یا در ابعاد نزدیک به آن جای گرفته‌اند، نیز به‌طور غیرقابل‌پیش‌بینی جابه‌جا کند؛ اثری جانبی که در فضایی غیربرهم‌نهیده، به‌طور ذاتی وجود نخواهد داشت.

۲.۵.۲ خودرمزگذارهای پراکنده به‌عنوان راه‌حل

خودرمزگذارهای پراکنده[۲۵] به‌عنوان ابزاری برای گشودن این برهم‌نهی معرفی شدند. ایدهٔ بنیادی، وام‌گرفته از حوزهٔ یادگیری فرهنگ‌لغت[۲۶] در پردازش سیگنال، این است که اگر بردار فعال‌سازی d بُعدی یک لایه، در واقع ترکیب خطی پراکنده‌ای از تعداد بسیار بیشتری «جهت ویژگی» زیرین $m \gg d$ باشد (که پدیدهٔ برهم‌نهی، دقیقاً چنین وضعیتی را پیش‌بینی می‌کند)، آنگاه می‌توان با آموزش یک شبکهٔ رمزگذار-رمزگشای کم‌عمق که فعال‌سازی را به یک کد m بُعدی پراکنده (اکثر مؤلفه‌ها صفر) می‌برد و سپس تلاش می‌کند فعال‌سازی اصلی را از روی همین کد بازسازی کند، این m جهت زیرین را بازیابی کرد. تابع هزینهٔ متداول آموزش چنین خودرمزگذاری، به‌طور کلاسیک به شکل

$$\mathcal{L}_{\text{SAE}} = \|x - \text{Dec}(\text{Enc}(x))\|_2^2 + \beta\|\text{Enc}(x)\|_1 \qquad (۲.۲)$$

صورت‌بندی می‌شود: جزء نخست، خطای بازسازی استاندارد یک خودرمزگذار، و جزء دوم، جریمه‌ای بر پایهٔ نُرم ℓ_1 کد پنهان که-به‌دلیل خاصیت نُرم ℓ_1 در ترغیب کدهای دقیقاً صفر (برخلاف نُرم ℓ_2 که مقادیر را کوچک اما غیرصفر نگاه می‌دارد)-پراکندگی کد حاصل را تشویق می‌کند؛ ضریب β مصالحه‌ای میان وفاداری بازسازی و درجهٔ پراکندگی را کنترل می‌کند. تابع بخش ۱.۵.۳ این پایان‌نامه (رابطهٔ ۱.۳)، از نظر جزء بازسازی، مستقیماً بر همین پایه بنا شده، با این تفاوت که در آن‌جا، به‌جای آموزش خود خودرمزگذار، همین خطای بازسازی به‌عنوان

[24] Polysemanticity
[25] Sparse Autoencoders, SAEs
[26] Dictionary Learning

یک سیگنال نظارتی برای مدل زبانی (نه خودرمزگذار) به کار می‌رود.

کار Cunningham و همکاران [۶] و هم‌زمان، Towards Monosemanticity از آنتروپیک [۴]، نشان دادند این رویکرد-با آموزش یک خودرمزگذار پراکندهٔ کم‌عمق روی فعال‌سازی‌های یک مدل زبانی از پیش‌آموزش‌دیده و ثابت-به‌طور سیستماتیک ویژگی‌هایی استخراج می‌کند که به‌مراتب تفسیرپذیرتر از نورون‌های خام‌اند، از ویژگی‌های نحوی و واژگانی ساده (مانند حضور یک کلمهٔ خاص در یک بافت نحوی مشخص) تا مفاهیم انتزاعی‌تر (مانند لحن یا موضوع کلی متن). Scaling Monosemanticity [۲۷] این رویکرد را به مقیاس یک مدل زبانی بزرگ در سطح تولید (Claude 3 Sonnet) گسترش داد و نشان داد ویژگی‌های استخراج‌شده می‌توانند مفاهیمی به‌مراتب انتزاعی‌تر، چندزبانه، و حتی چندوجهی (فعال در واکنش به هم متن و هم تصویر یک مفهوم) را نمایش دهند؛ این کار همچنین نشان داد این ویژگی‌ها، صرفاً همبستگی آماری نیستند، بلکه با دستکاری مقدار آن‌ها (بخش ۳.۵.۲) می‌توان رفتار خروجی مدل را در جهت مفهوم متناظر تغییر داد-شاهدی بر نقش علّی این ویژگی‌ها در محاسبات مدل.

از نظر فنی، کار اصلی این پژوهش‌ها-و همچنین کتابخانهٔ SAELens [۳] که این پایان‌نامه برای بارگذاری خودرمزگذارهای از پیش‌آموزش‌دیده از آن استفاده کرده-بر پایهٔ همان تابع هزینهٔ بازسازی + جریمهٔ ℓ_1 است. توسعه‌های معماری بعدی، تلاش سیستماتیکی برای بهبود مصالحهٔ ذاتی این تابع هزینه-میان پراکندگی کد، وفاداری بازسازی، و جلوگیری از «ویژگی‌های مرده»[۲۷] (ابعادی از کد که هرگز یا تقریباً هرگز فعال نمی‌شوند و در نتیجه هیچ اطلاعاتی حمل نمی‌کنند)-بوده‌اند. خودرمزگذارهای TopK [۱۲] به‌جای جریمهٔ نرم ℓ_1، مستقیماً و به‌صراحت تنها k فعال‌ترین بُعد کد را نگه می‌دارند و بقیه را صفر می‌کنند؛ این رویکرد، پراکندگی کد را به‌طور دقیق و از پیش‌تعیین‌شده تضمین می‌کند، بدون آنکه نیاز به تنظیم ظریف ضریب جریمهٔ ℓ_1 باشد. خودرمزگذارهای JumpReLU [۲۴] رویکرد دیگری در پیش گرفتند: با جایگزین‌کردن تابع فعال‌سازی ReLU با یک تابع آستانه‌گذاری آموختنی (که برای هر بُعد کد، آستانهٔ متفاوتی می‌آموزد)، مستقیماً مصالحهٔ میان پراکندگی و خطای بازسازی را بهینه می‌کنند، بدون کوچک‌ترشدن سیستماتیک دامنهٔ ویژگی‌های واقعاً فعال-اثر جانبی ناخواسته‌ای که جریمهٔ ℓ_1 علاوه بر تشویق پراکندگی، به‌طور طبیعی به همراه دارد.

این پایان‌نامه، به‌جای آموزش یک خودرمزگذار جدید یا مقایسهٔ معماری‌های مختلف آن، از یک خودرمزگذار از پیش‌آموزش‌دیده و منتشرشده (با معماری استاندارد بازسازی+ ℓ_1) به‌عنوان جزئی ثابت و آماده استفاده می‌کند؛ سهم این پایان‌نامه، نه در بهبود خود خودرمزگذار، بلکه در یافتن کاربرد تازه‌ای برای آن است (بخش ۳.۵.۲).

[27] Dead Features

۳.۵.۲ فراتر از تحلیل: هدایت و مهندسی بازنمایی

کاربرد غالب خودرمزگذارهای پراکنده، همچنان تحلیل پس‌ازآموزش یک مدل ثابت است: مدل آموزش داده می‌شود، سپس خودرمزگذار روی فعال‌سازی‌های آن آموزش می‌بیند، و سرانجام ویژگی‌های حاصل بررسی و نام‌گذاری می‌شوند. اما این حوزه به‌تدریج به کاربردهای مداخله‌گر نیز گسترش یافته است. Turner و همکاران [۲۸] نشان دادند می‌توان با افزودن یک بردار جهت ثابت (برآمده از تفاوت فعال‌سازی دو دستهٔ متن متضاد، مانند متن «شاد» در برابر «غمگین») به فعال‌سازی مدل در زمان استنتاج، رفتار خروجی مدل را-بدون هیچ‌گونه ریزتنظیمی و تنها با یک عملیات برداری ساده در زمان اجرا-در جهت مورد نظر «هدایت»[۲۸] کرد. Scaling Monosemanticity [۲۷] نیز نشان داد وقتی این بردارهای جهت از میان ویژگی‌های یک خودرمزگذار پراکنده (به‌جای جهت‌های دستی‌ساخته از تفاضل دو دسته متن) استخراج شوند، هدایت حاصل می‌تواند دقیق‌تر و موضعی‌تر باشد، چون هر ویژگی، به‌لطف پراکندگی کد، تداخل کمتری با مفاهیم نامرتبط دارد. Zou و همکاران، در چارچوبی که «مهندسی بازنمایی»[۲۹] [۳۴] می‌نامند، این ایده را به یک رویکرد کلی‌تر بالا-به-پایین برای شفافیت هوش مصنوعی-شناسایی جهت‌های مفهومی (نه لزوماً از طریق خودرمزگذار، بلکه با روش‌های ساده‌تر آماری) و مداخله در آن‌ها، به‌جای تحلیل مدارهای پایین-به-بالا و مدارمحور-تعمیم داده‌اند.

همهٔ کاربردهای بالا-چه هدایت مبتنی بر تفاضل فعال‌سازی و چه هدایت مبتنی بر ویژگی خودرمزگذار-یک ویژگی مشترک دارند: خودرمزگذار (یا بردار جهت)، پس از آموزش کامل مدل و به‌عنوان یک لایهٔ مداخلهٔ زمان استنتاج به کار می‌رود؛ وزن‌های خود مدل زبانی دست‌نخورده باقی می‌مانند، و هدایت باید در هر بار فراخوانی مدل، دوباره اعمال شود. رویکرد این پایان‌نامه، از این جهت، ماهیتاً متفاوت است: خودرمزگذار نه در زمان استنتاج، بلکه در زمان آموزش و نه به‌عنوان مداخله‌گر بلکه به‌عنوان فضای محاسبهٔ تابع هزینه به کار می‌رود؛ نتیجهٔ نهایی، تغییری ماندگار در خود وزن‌های مدل (از طریق لورا) است، نه یک بردار افزودنی جداگانه که در زمان استنتاج باید اعمال شود-با این پیامد که، برخلاف هدایت زمان استنتاج، خودرمزگذار پس از پایان آموزش دیگر برای بهره‌گیری از مدل ریزتنظیم‌شده لازم نیست. تا آنجا که در چارچوب این پایان‌نامه بررسی شده، این کاربرد-استفاده از یک خودرمزگذار ثابت به‌عنوان عدسی یک تابع هزینهٔ آموزشی-در ادبیات موجود کمتر مورد بررسی مستقیم قرار گرفته است.

[28] Steering
[29] Representation Engineering

۴.۵.۲ نقد و محدودیت‌های کاربردی

شایان ذکر است که سودمندی عملی خودرمزگذارهای پراکنده-حتی در همان کاربردهای مرسوم‌تر-بدون چالش نیست، و این پایان‌نامه از پذیرش بی‌قیدوشرط برتری آن‌ها پرهیز می‌کند. Kantamneni و همکاران [۱۶] در بررسی کاربرد خودرمزگذارها برای کاوش[۳۰] مفاهیم-یعنی آموختن یک طبقه‌بندی‌کنندهٔ ساده روی کد خودرمزگذار برای پیش‌بینی یک ویژگی مورد نظر-نشان دادند در بسیاری از تنظیمات، یک طبقه‌بندی‌کنندهٔ خطی مستقیم روی فعال‌سازی خام (بدون هیچ خودرمزگذاری) می‌تواند عملکردی هم‌تراز یا حتی بهتر داشته باشد؛ به بیان دیگر، پراکنده‌ترکردن بازنمایی، همیشه یک مسئلهٔ پایین‌دستی نظارت‌شده را ساده‌تر نمی‌کند. به‌طور مشابه، Wu و همکاران در چارچوب AxBench [۳۱] در بررسی کاربرد خودرمزگذارها برای هدایت رفتار مدل (بخش ۳.۵.۲)، نشان دادند در مقایسه با پایه‌های ساده-مانند تفاضل‌میانگین فعال‌سازی میان دو دستهٔ متن متضاد، بدون هیچ خودرمزگذاری-بردارهای برآمده از خودرمزگذار، همیشه برتری قابل‌توجهی در کیفیت هدایت نشان نمی‌دهند و گاه حتی عملکرد ضعیف‌تری دارند.

این یافته‌ها هشداری روش‌شناختی برای این پایان‌نامه‌اند: نمی‌توان صرفاً فرض کرد فضای خودرمزگذار «به‌طور ذاتی» و بدون هیچ آزمونی، برای هر کاربردی-از جمله کاربرد تازهٔ این پایان‌نامه، یعنی محاسبهٔ یک تابع هزینهٔ آموزشی-بهتر از فضای خام است؛ برتری آن باید در هر کاربرد مشخص، به‌طور تجربی و در برابر یک مبنای مقایسه‌ای مبتنی بر فضای خام سنجیده شود. این پایان‌نامه دقیقاً همین رویکرد را، با گنجاندن شرط کنترلی C2 (اعمال همان تابع هزینه، اما در فضای خام؛ بخش ۷.۳)، در پیش گرفته است؛ نتایج فصل چهارم (بخش ۲.۴) نشان می‌دهند که، دست‌کم در این کاربرد خاص و بر روی این مدل، فضای خودرمزگذار واقعاً برتری قابل‌سنجش دارد-اما این نتیجه، خروجی یک آزمایش کنترل‌شده است، نه یک فرض پیشینی.

۶.۲ ریزتنظیم کارآمد پارامتر و حفظ رفتار مدل

۱.۶.۲ روش‌های ریزتنظیم کارآمد پارامتر

با بزرگ‌ترشدن مدل‌های زبانی، ریزتنظیم کامل تمام پارامترها برای هر وظیفهٔ جدید، هم از نظر محاسباتی و هم از نظر حافظه (چرا که بهینه‌سازهایی مانند Adam به ازای هر پارامتر، چند مقدار کمکی اضافی نگه می‌دارند)، پرهزینه شده است. روش‌های ریزتنظیم کارآمد پارامتر[۳۱] با این هدف طراحی شده‌اند که تنها بخش کوچکی

[30] Probing
[31] Parameter-Efficient Fine-Tuning, PEFT

از پارامترها (یا پارامترهای افزودنی جدید) آموزش داده شوند، درحالی‌که بیشتر وزن‌های از پیش‌آموزش‌دیده ثابت باقی می‌مانند. Adapters [۱۴] از نخستین رویکردهای این خانواده بودند: افزودن لایه‌های کوچک میانی (معمولاً یک گلوگاه دوبُعدی کاهشی-افزایشی) به هر بلوک ترنسفورمر، به‌گونه‌ای که تنها همین لایه‌های افزوده‌شده آموزش داده شوند. Prefix-Tuning [۲۰] و Prompt Tuning [۱۹] رویکرد دیگری در پیش گرفتند: به‌جای تغییر معماری درونی مدل، بردارهای پیوستهٔ آموختنی («پیشوند» یا «اعلان») به ورودی مدل (یا به حالت‌های کلید-مقدار توجه) افزوده می‌شوند، و مدل اصلی کاملاً دست‌نخورده باقی می‌ماند.

لورا [۱۵]-روشی که این پایان‌نامه از آن استفاده کرده-رویکرد سومی را پیش گرفت: به‌جای افزودن لایه یا توکن جدید، یک به‌روزرسانی کم‌رتبه مستقیماً به ماتریس‌های وزن موجود افزوده می‌شود (جزئیات ریاضی در بخش ۳.۳). مزیت عملی این رویکرد نسبت به دو رویکرد پیشین دوگانه است: نخست، پس از آموزش، می‌توان به‌روزرسانی کم‌رتبه را مستقیماً در وزن اصلی ادغام کرد و هیچ سربار محاسباتی‌ای-نه در طول دنباله (برخلاف Prefix-Tuning که طول مؤثر دنباله را افزایش می‌دهد) و نه در ساختار شبکه (برخلاف Adapters)- در زمان استنتاج باقی نمی‌ماند؛ دوم، فضای پارامترهای قابل‌آموزش (ماتریس‌های A و B) به‌طور طبیعی با رتبهٔ r مقیاس‌پذیر است، که امکان کنترل دقیق مصالحهٔ میان ظرفیت تطبیق و صرفه‌جویی محاسباتی را فراهم می‌کند.

از منظر این پایان‌نامه، معیار انتخاب میان این رویکردهای مختلف PEFT تنها کارآمدی پارامتر نبود، بلکه سازگاری با طرح آزمایش شبکه‌ای (بخش ۸.۳) نیز اهمیت داشت: از آنجا که هر یک از ۱۶۰ پیکربندی باید به‌طور کاملاً مستقل و از ابتدا آموزش می‌دید، روشی که پس از آموزش، بار اضافه‌ای (نه در معماری و نه در طول دنباله) به مدل نهایی تحمیل نکند، برای مدیریت‌پذیری عملی این حجم از اجراها ترجیح داده شد؛ لورا، با قابلیت ادغام‌شدن کامل خود در وزن اصلی پس از آموزش، این ویژگی را به‌طور طبیعی برآورده می‌کند. افزون‌بر این، از آنجا که تابع هزینهٔ ناوردایی (بخش ۶.۳) بر روی فعال‌سازی جریان باقیمانده در یک لایهٔ مشخص تعریف می‌شود، روشی که مستقیماً وزن‌های همان لایه‌ها را تطبیق دهد (مانند لورا، که می‌تواند به‌صورت گزینشی تنها به ماتریس‌های وزن لایه‌های مورد نظر اعمال شود)، از نظر مفهومی سرراست‌تر از روشی است که طول دنباله یا معماری شبکه را تغییر می‌دهد.

۲.۶.۲ حفظ رفتار مدل در حین ریزتنظیم

ریزتنظیم کارآمد پارامتر، مسئلهٔ حجم پارامترهای آموزش‌دیده را حل می‌کند، اما مسئلهٔ جداگانه‌ای را حل‌نشده باقی می‌گذارد: حتی با تعداد کمی پارامتر قابل‌آموزش، ریزتنظیم متمرکز بر یک وظیفهٔ باریک می‌تواند توانایی‌های عمومی‌تر مدل را تضعیف کند؛ پدیده‌ای که در ادبیات یادگیری پیوسته با عنوان فراموشی فاجعه‌بار[۳۲] شناخته

[32] Catastrophic Forgetting

می‌شود. Kirkpatrick و همکاران [۱۸] یکی از نخستین راه‌حل‌های سیستماتیک برای این مسئله را با روش تحکیم وزن کشسان[۳۳] ارائه کردند: پارامترهایی که برای وظیفهٔ قبلی اهمیت بیشتری داشته‌اند (بر اساس اطلاعات فیشر[۳۴]، که به‌طور تقریبی، حساسیت تابع هزینهٔ وظیفهٔ قبلی را نسبت به هر پارامتر می‌سنجد) با جریمهٔ سنگین‌تری-متناسب با مربع فاصله از مقدار قبلی‌شان-از تغییر زیاد بازداشته می‌شوند؛ پارامترهایی که اهمیت کمتری داشته‌اند، آزادانه‌تر تغییر می‌کنند.

الگوی مشابهی، اما در سطح رفتار خروجی مدل به‌جای پارامترهای منفرد، در ادبیات یادگیری تقویتی مبتنی بر بازخورد انسانی[۳۵] دیده می‌شود. InstructGPT [۲۳] نشان داد وقتی یک مدل زبانی صرفاً با هدف بیشینه‌سازی یک سیگنال پاداش (اینجا: ترجیح انسانی، خود برآمده از یک مدل پاداش جداگانه) بهینه شود، می‌تواند به شکلی نامطلوب-با یافتن راه‌های میان‌بُری که مدل پاداش را فریب می‌دهند بدون آنکه واقعاً کیفیت خروجی را بهبود دهند-از رفتار زبانی اصیل خود و حتی از حقیقت دور شود. برای مهار این پدیده، یک جریمهٔ واگرایی کولبک-لایبلر نسبت به سیاست اولیه (پیش از یادگیری تقویتی) به تابع هزینه افزوده شد، دقیقاً برای آنکه مدل در ناحیه‌ای از فضای رفتار بماند که «شبیه به» مدل اصیل باقی بماند، درحالی‌که هم‌زمان در جهت هدف جدید (ترجیح انسانی) نیز پیش می‌رود.

۳.۶.۲ اعتبار ابزارهای سنجش ثابت در حین آموزش

نکته‌ای که در هر دو مثال بالا مشترک است-و مستقیماً به ریسک رانش خودرمزگذار این پایان‌نامه (بخش ۱.۵.۳) مرتبط می‌شود-وجود یک «ابزار سنجش ثابت» است که در حین بهینه‌سازی، خودش تغییر نمی‌کند اما مبنای سنجش موفقیت یا محدودیت قرار می‌گیرد: در EWC، این ابزار، مقدار اطلاعات فیشر محاسبه‌شده روی مدل اولیه است؛ در RLHF، این ابزار، هم سیاست اولیه (برای جریمهٔ کولبک-لایبلر) و هم خود مدل پاداش است، که اگر سیاست درحال‌آموزش بیش‌ازحد از توزیع داده‌ای که مدل پاداش روی آن آموزش دیده دور شود، دیگر نمی‌توان به خروجی آن اعتماد کرد. در این پایان‌نامه، این ابزار سنجش ثابت، خودرمزگذار پراکنده است: سنجهٔ اصلی موفقیت (جداسازی هم‌معنی/ناهم‌معنی) تنها زمانی معنادار است که خودرمزگذار همچنان بازسازی‌کنندهٔ باکیفیتی از فعال‌سازی‌های مدل باشد.

منظم‌ساز بازسازی این پایان‌نامه (بخش ۱.۵.۳)، از نظر نقش مفهومی-نه از نظر فرمول ریاضی-با هر سه رویکرد بالا خویشاوند است: در همهٔ موارد، یک جزء تابع هزینه، مدل را از دورشدن بیش‌ازحد از یک نقطهٔ مرجع ثابت بازمی‌دارد، درحالی‌که جزء دیگر، مدل را در جهت هدف تازه پیش می‌راند. تفاوت کلیدی آن است

[33] Elastic Weight Consolidation, EWC
[34] Fisher Information
[35] Reinforcement Learning from Human Feedback, RLHF

که در EWC، نقطهٔ مرجع، پارامترهای مدل هستند؛ در RLHF، نقطهٔ مرجع، توزیع خروجی مدل و اعتبار مدل پاداش است؛ و در این پایان‌نامه، نقطهٔ مرجع، نه پارامتر و نه خروجی، بلکه قابلیت بازسازی فعال‌سازی‌ها توسط یک ابزار سنجش شخص ثالث است.

۷.۲ جمع‌بندی و جایگاه این پژوهش

مرور بالا نشان می‌دهد سه ادعای بنیادی این پایان‌نامه، هرکدام به‌طور مستقل در ادبیات موجود پشتوانه دارند: اینکه بازنمایی خام مدل‌های زبانی، حتی وقتی بافتاری است، لزوماً معناداری‌ای در سطح مورد نظر انسان ندارد، و مجموعه‌دادهٔ PAWS ابزار مناسبی برای آشکارسازی این نبود است (بخش ۲.۲)؛ اینکه یک تابع هزینهٔ تقابلی، به‌ویژه با تکیه بر نمونه‌های منفی سخت، می‌تواند فضای بازنمایی را در جهت یک سنجهٔ معنایی مشخص شکل دهد (بخش ۴.۲)؛ و اینکه فضای خام فعال‌سازی، به‌دلیل برهم‌نهی ویژگی‌ها، مسیر ایده‌آلی برای این نوع مداخله نیست، درحالی‌که خودرمزگذارهای پراکنده برای گشودن همین برهم‌نهی طراحی شده‌اند-هرچند سودمندی عملی آن‌ها، آن‌گونه که نقدهای اخیر نشان می‌دهند، باید در هر کاربرد به‌طور مستقل آزموده شود، نه مفروض گرفته شود (بخش ۵.۲).

جدول ۱.۲ این پایان‌نامه را در برابر نزدیک‌ترین خطوط پژوهشی مرورشده، از نظر سه محور کلیدی، جای‌گذاری می‌کند.

جدول ۱.۲: جایگاه این پژوهش نسبت به نزدیک‌ترین خطوط پژوهشی مرورشده.

	نقش خودرمزگذار	زمان اعمال	اثر بر وزن‌های مدل
تفسیرپذیری پس‌ازآموزش (مثل [۴])	ابزار تحلیل و کشف	پس از آموزش کامل	بدون اثر
هدایت زمان استنتاج (مثل [۲۷، ۲۸])	اهرم مداخله	زمان استنتاج، هر بار	بدون اثر (مداخله‌ای جدا)
یادگیری تقابلی متعارف (مثل [۱۳])	بدون خودرمزگذار (فضای خام یا مدل جدا)	زمان آموزش	مستقیم
این پایان‌نامه	فضای هدف تابع هزینه	زمان آموزش	مستقیم

آنچه در ادبیات بررسی‌شده یافت نشد-و شکافی است که این پایان‌نامه می‌کوشد آن را پر کند-ترکیب این سه ادعا در یک روش واحد است، آن‌گونه که در ستون آخر جدول بالا خلاصه شده: استفاده از خودرمزگذار پراکنده، نه به‌عنوان ابزار تحلیل پس‌ازآموزش و نه به‌عنوان اهرم هدایت زمان استنتاج، بلکه به‌عنوان فضای هدف یک تابع هزینهٔ تقابلی که مستقیماً وزن‌های مدل را-با روشی کارآمد پارامتر و با یک منظم‌ساز صریح برای حفظ اعتبار همان خودرمزگذار (بخش ۶.۲)-در حین آموزش تغییر می‌دهد. فصل سوم، پیاده‌سازی دقیق این ترکیب را شرح می‌دهد.

فصل ۳

روش پیشنهادی

۱.۳ مقدمه

این فصل، پیاده‌سازی دقیق ایده‌ای را شرح می‌دهد که در فصل اول معرفی شد: ریزتنظیم یک مدل زبانی، به‌گونه‌ای که بازنمایی جفت‌جمله‌های هم‌معنی و ناهم‌معنی مجموعه‌دادهٔ PAWS در فضای نهان یک خودرمزگذار پراکندهٔ ثابت، بهتر از یکدیگر تفکیک شوند. ساختار فصل به این ترتیب است: ابتدا نمای کلی معماری و جریان داده در بخش ۲.۳ ارائه می‌شود؛ سپس مدل پایه و روش تطبیق کارآمد پارامتر (بخش ۳.۳)، دادگان (بخش ۴.۳)، و مکانیسم خودرمزگذار ثابت و قلاب‌کردن جریان باقیمانده (بخش ۵.۳) معرفی می‌شوند. بخش ۶.۳ تابع هزینهٔ کامل را با جزئیات ریاضی شرح می‌دهد، بخش ۷.۳ چهار شرط آزمایشی را تعریف می‌کند، بخش ۸.۳ طرح آزمایش‌های شبکه‌ای را می‌آورد، بخش ۹.۳ معیارهای ارزیابی را تعریف می‌کند و سرانجام بخش ۱۰.۳ جزئیات پیاده‌سازی و ابرپارامترها را فهرست می‌کند.

۲.۳ نمای کلی معماری

شکل ۱.۳ جریان کلی داده و محاسبهٔ تابع هزینه را نشان می‌دهد. در هر گام از آموزش، دو دستهٔ داده به‌طور موازی از یک مدل مشترک (مدل پایه به‌همراه تطبیق‌دهندهٔ لورا؛ بخش ۳.۳) عبور داده می‌شوند و در نهایت، چهار جزء تابع هزینه را می‌سازند که مجموعشان، تابع هزینهٔ نهایی است.

مسیر PAWS (نیمهٔ بالایی شکل). یک دستهٔ جفت‌جمله-شامل چند جفت هم‌معنی و چند جفت ناهم‌معنی- از مدل عبور داده می‌شود. فعال‌سازی هر جمله در لایهٔ هدف قلاب و گرفته می‌شود، و پس از عبور از خودرمزگذار ثابت (رمزگذاری)، به کدی نهان تبدیل می‌شود. از این نقطه، دو مسیر موازی طی می‌شود: در مسیر نخست، کدهای نهان هر جمله تجمیع (میانگین‌گیری روی نشانه‌ها) شده و شباهت کسینوسی آن‌ها، مبنای تابع هزینهٔ ناوردایی قرار می‌گیرد؛ در مسیر دوم-که مستقل از تجمیع است-همان کدهای نهان از خودرمزگذار رمزگشایی می‌شوند و خطای بازسازی حاصل، مبنای منظم‌ساز بازسازی روی دستهٔ PAWS قرار می‌گیرد.

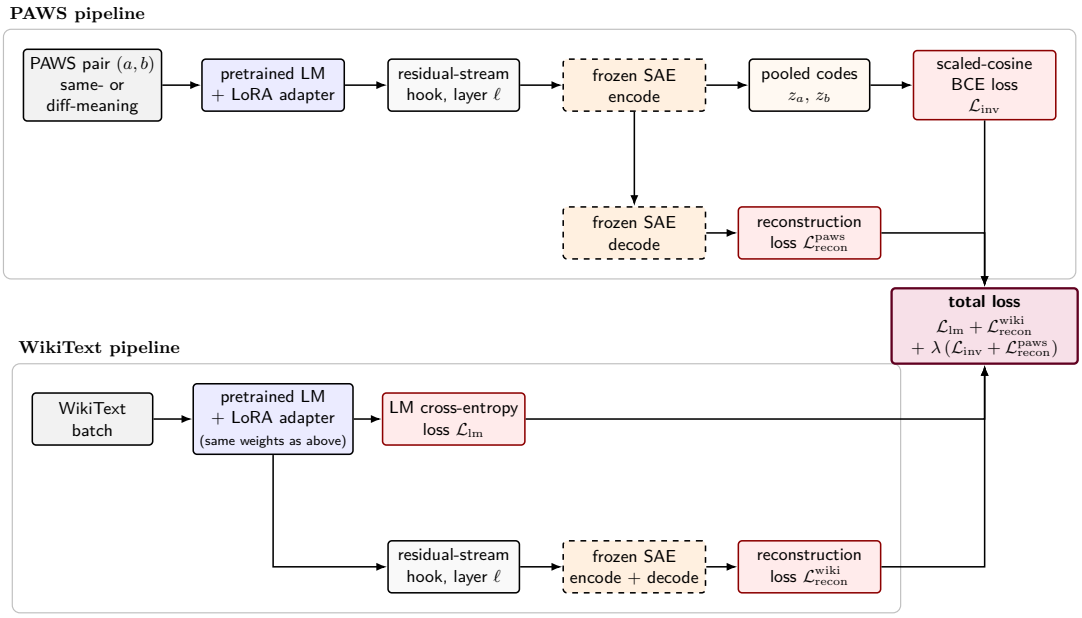
مسیر WikiText (نیمهٔ پایین شکل). یک دستهٔ متن عمومی از پیکرهٔ WikiText-2 نیز از همان مدل عبور داده می‌شود و به دو منظور به کار می‌رود: نخست، محاسبهٔ هزینهٔ آنتروپی متقاطع استاندارد زبان‌مدل‌سازی؛ دوم، قلاب‌کردن فعال‌سازی همین دسته در لایهٔ هدف و عبور آن از خودرمزگذار ثابت (رمزگذاری و سپس بلافاصله رمزگشایی) برای محاسبهٔ منظم‌ساز بازسازی روی دستهٔ WikiText.

همگرایی در تابع هزینهٔ کل. هر چهار جزء-هزینهٔ زبان‌مدل‌سازی، منظم‌ساز بازسازی WikiText، تابع هزینهٔ ناوردایی، و منظم‌ساز بازسازی PAWS-در تابع هزینهٔ نهایی جمع می‌شوند (فرمول دقیق در بخش ۶.۳). تنها گرادیان همین تابع هزینهٔ نهایی است که به پارامترهای قابل‌آموزش-یعنی تطبیق‌دهندهٔ لورا، به‌علاوهٔ دو پارامتر مقیاس و بایاس تابع هزینهٔ ناوردایی-بازمی‌گردد؛ همان‌طور که در شکل با حاشیهٔ نقطه‌چین مشخص شده، پارامترهای خود خودرمزگذار در هر دو مسیر، در سرتاسر آموزش کاملاً ثابت می‌مانند و هیچ گرادیانی به داخل آن‌ها انباشته نمی‌شود.

۳.۳ مدل پایه و تطبیق کارآمد پارامتر

مدل پایهٔ مورد استفاده در تمام آزمایش‌های این پایان‌نامه، Pythia-70m-deduped [۱] است: عضو کوچک‌ترین خانوادهٔ مدل‌های Pythia، توسعه‌یافته توسط EleutherAI بر پایهٔ معماری GPT-NeoX [۲] و پیش‌آموزش‌دیده روی نسخهٔ حذف‌تکرارشدهٔ[1] پیکرهٔ The Pile [۱۱]. این مدل ۶ لایهٔ ترنسفورمر و ابعاد جریان باقیماندهٔ ۵۱۲ دارد. انتخاب این مدل، دو دلیل عملی داشت: نخست، خانوادهٔ Pythia به‌طور خاص برای پژوهش‌های تحلیلی و قابلیت تکرارپذیری طراحی شده است [۱]؛ دوم، وجود مجموعه‌ای از خودرمزگذارهای پراکندهٔ از پیش‌آموزش‌دیده و عمومی برای این مدل (قابل‌بارگذاری از طریق کتابخانهٔ SAELens [۳])، پیش‌نیاز مستقیم روش پیشنهادی را

[1] Deduplicated



شکل ۳.۱: نمای کلی معماری و جریان محاسبهٔ تابع هزینه. پنل بالا مسیر جفت‌جمله‌های PAWS را نشان می‌دهد که هم به تابع هزینهٔ ناوردایی و هم به منظم‌ساز بازسازی خود PAWS می‌انجامد؛ پنل پایین مسیر WikiText را نشان می‌دهد که هم به هزینهٔ زبان‌مدل‌سازی و هم به منظم‌ساز بازسازی WikiText می‌انجامد. کادرهای با حاشیهٔ نقطه‌چین (خودرمزگذار ثابت) پارامترهایی را نشان می‌دهند که هرگز به‌روزرسانی نمی‌شوند؛ گرادیان تنها از طریق تطبیق‌دهندهٔ لورای مشترک (که در هر دو پنل، همان وزن‌های یکسان است) به پارامترهای قابل‌آموزش بازمی‌گردد.

برآورده می‌کند. کوچکی این مدل همچنین امکان اجرای شبکهٔ آزمایشی نسبتاً بزرگ این پژوهش (بخش ۸.۳) را در محدودهٔ منابع محاسباتی در دسترس فراهم کرد؛ در فصل پنجم به این انتخاب و پیامدهای آن برای تعمیم‌پذیری نتایج بازمی‌گردیم.

برای ریزتنظیم کارآمد پارامتر، از روش لورا[۲] [۱۵] استفاده شده است. لورا به‌جای به‌روزرسانی مستقیم ماتریس‌های وزن از پیش‌آموزش‌دیده، برای هر ماتریس هدف $W_\circ \in \mathbb{R}^{d\times k}$ یک به‌روزرسانی کم‌رتبه به شکل $\Delta W = BA$ می‌افزاید، که در آن $B \in \mathbb{R}^{d\times r}$ و $A \in \mathbb{R}^{r\times k}$ با $r \ll \min(d, k)$ هستند و تنها همین دو ماتریس کوچک آموزش داده می‌شوند؛ خروجی لایه به‌صورت $W_\circ x + \frac{\alpha}{r} BAx$ محاسبه می‌شود، که در آن α یک ضریب مقیاس‌دهی ثابت است. در این پژوهش، لورا روی ماتریس‌های تصویر ترکیبی پرسمان-کلید-مقدار و تصویر خروجی بلوک توجه اعمال شده است؛ مقادیر دقیق رتبه، ضریب مقیاس، و دراپ‌اوت در پیوست «الف» فهرست شده‌اند. تمام لایه‌های مدل به‌طور یکسان تطبیق‌پذیرند؛ آنچه میان شرایط مختلف آزمایشی تغییر می‌کند،

[2] Low-Rank Adaptation, LoRA

محل اعمال تابع هزینهٔ ناوردایی است (بخش ۸.۳)، نه محل اعمال لورا.

۴.۳ دادگان

دو منبع داده در آموزش نقش دارند:

PAWS. مجموعه‌دادهٔ PAWS [۳۳] (زیرمجموعهٔ labeled_final) منبع سیگنال نظارتی اصلی است. هر جفت‌جمله برچسب دودویی هم‌معنی/ناهم‌معنی دارد. برای هر یک از سه شکاف استاندارد (آموزش، اعتبارسنجی، آزمون)، به‌طور مستقل، تعداد برابری جفت هم‌معنی و ناهم‌معنی-با یک بذر تصادفی ثابت برای تکرارپذیری- نمونه‌برداری شده است؛ اندازهٔ دقیق هر شکاف در پیوست «الف» آمده است. شکاف آزمون، تا پایان آموزش هر پیکربندی، هرگز مورد استفاده قرار نمی‌گیرد و تنها در مرحلهٔ ارزیابی نهایی (فصل چهارم) به کار می‌رود؛ شکاف اعتبارسنجی، برای پایش دوره‌ای سلامت آموزش (بخش ۱۰.۳) استفاده می‌شود.

WikiText-2. برای جلوگیری از افت کیفیت عمومی زبان‌مدل‌سازی در حین ریزتنظیم متمرکز بر PAWS (پدیده‌ای که در ادبیات یادگیری پیوسته با عنوان فراموشی فاجعه‌بار[۳] شناخته می‌شود [۱۸])، در هر گام آموزش، یک دستهٔ متن عمومی نیز از نسخهٔ خام WikiText-2 نمونه‌برداری و همراه با دستهٔ PAWS از مدل عبور داده می‌شود. متن خام به بلوک‌هایی با طول ثابت بریده می‌شود؛ بخش پایانی مجموعه برای اعتبارسنجی کنار گذاشته شده و باقی برای آموزش استفاده می‌شود.

۵.۳ خودرمزگذار پراکنده‌ٔ ثابت

برای هر لایهٔ مدل، یک خودرمزگذار پراکنده[۴] از پیش‌آموزش‌دیده و عمومی (منتشرشده در مخزن SAELens [۳]) بارگذاری می‌شود. این خودرمزگذار، بردار فعال‌سازی جریان باقیمانده را (پس از هر بلوک، یعنی در نقطهٔ قلاب استاندارد hook_resid_post) به یک کد پراکنده با ابعاد بسیار بیشتر می‌برد، و سپس تلاش می‌کند از روی همین کد، بردار اصلی را بازسازی کند. تابع رمزگذاری و رمزگشایی آن را به‌ترتیب با $\mathrm{Enc}(\cdot)$ و $\mathrm{Dec}(\cdot)$ نشان می‌دهیم.

[3] Catastrophic Forgetting
[4] Sparse Autoencoder, SAE

نکتهٔ کلیدی پیاده‌سازی آن است که تمام پارامترهای این خودرمزگذار، در سرتاسر آموزش، منجمد نگه داشته می‌شوند: هیچ گرادیانی به داخل پارامترهای خودرمزگذار انباشته نمی‌شود. با این‌همه، از آنجا که منجمدبودن یک ماژول مانع عبور گرادیان از میان آن به ورودی‌اش نمی‌شود، سیگنال گرادیانی حاصل از تابع هزینه‌ای که روی خروجی $\mathrm{Enc}(\cdot)$ محاسبه شده، همچنان می‌تواند از میان خودرمزگذار عبور کرده و به فعال‌سازی‌های مدل-و از آن‌جا، به پارامترهای لورا-برسد. همین ویژگی است که امکان استفاده از خودرمزگذار به‌عنوان «عدسی ثابت» تابع هزینه (نه هدف آموزش) را فراهم می‌کند؛ الگویی مشابه با استفاده از یک شبکهٔ ثابت از پیش‌آموزش‌دیده در تابع هزینه‌های ادراکی[5] در بینایی ماشین.

۱.۵.۳ ریسک رانش خودرمزگذار و راه‌حل پیشنهادی

استفاده از یک خودرمزگذار ثابت به‌عنوان ابزار سنجش، به این فرض متکی است که فعال‌سازی‌های مدل، پس از ریزتنظیم، همچنان در ناحیه‌ای از فضای فعال‌سازی قرار داشته باشند که این خودرمزگذار روی آن آموزش دیده و می‌تواند آن را با دقت قابل‌قبولی بازسازی کند. اگر ریزتنظیم فعال‌سازی‌ها را به‌گونه‌ای جابه‌جا کند که این فرض نقض شود-پدیده‌ای که در این پایان‌نامه «رانش خودرمزگذار»[6] نامیده می‌شود-آنگاه هر سنجه‌ای که در فضای این خودرمزگذار محاسبه شود (از جمله سنجهٔ اصلی این پژوهش، یعنی جدایی هم‌معنی/ناهم‌معنی در فضای SAE) دیگر لزوماً بازتابی از تغییر واقعی در بازنمایی مدل نیست، بلکه می‌تواند بازتابی از عبور فعال‌سازی‌ها از میان یک ابزار سنجش نامنطبق باشد.

برای مهار این ریسک، خودرمزگذار در سرتاسر آموزش کاملاً ثابت نگه داشته می‌شود (بدون هیچ تغییری در وزن‌های خودش)، و در عوض، هزینهٔ بازسازی آن-محاسبه‌شده هم روی فعال‌سازی‌های دستهٔ WikiText و هم روی فعال‌سازی‌های دستهٔ PAWS-به‌عنوان یک جزء اضافی به تابع هزینهٔ کلی افزوده می‌شود. از آنجا که خودرمزگذار ثابت است، تنها مسیری که این جزء گرادیان می‌تواند طی کند، بازگشت از میان خودرمزگذار به خود فعال‌سازی‌ها-یعنی به پارامترهای لورایی است که این فعال‌سازی‌ها را تولید کرده‌اند. نتیجه، نیرویی است که مدل را وامی‌دارد در ناحیه‌ای از فضای فعال‌سازی بماند که خودرمزگذار همچنان می‌تواند آن را با وفاداری قابل‌قبولی بازسازی کند؛ این سازوکار از نظر مفهومی با جریمهٔ واگرایی کولبک-لایبلر نسبت به یک سیاست مرجع در یادگیری تقویتی مبتنی بر بازخورد انسانی [۲۳] قابل‌مقایسه است: در هر دو مورد، یک جزء تابع هزینه، مدل را از دورشدن بیش‌ازحد از یک نقطهٔ مرجع ثابت (به‌ترتیب، خودرمزگذار از پیش‌آموزش‌دیده، یا سیاست پیش‌آموزش‌دیده) بازمی‌دارد، درحالی‌که جزء دیگر تابع هزینه مدل را در جهت هدف اصلی (به‌ترتیب، جداسازی

[5] Perceptual Loss
[6] SAE Drift

هم‌معنی/ناهم‌معنی، یا هم‌سویی رفتاری) پیش می‌برد. تمام نتایج این پایان‌نامه با همین رویکرد-خودرمزگذار کاملاً ثابت به‌همراه منظم‌ساز بازسازی-به دست آمده‌اند.

۲.۵.۳ فرمول منظم‌ساز بازسازی

با فرض آنکه X دسته‌ای از بردارهای فعال‌سازی باشد، خطای بازسازی نرمال‌شدهٔ این دسته به‌صورت نسبت مجموع خطاهای مربعی به مجموع نُرم‌های مربعی تعریف می‌شود:

$$\mathcal{L}_{\text{recon}}(X) = \frac{\sum_{x \in X} \|\text{Dec}(\text{Enc}(x)) - x\|_2^2}{\sum_{x \in X} \|x\|_2^2} \tag{۱.۳}$$

نکتهٔ فنی مهم در این فرمول، جمع‌بندی‌کردن صورت و مخرج پیش از تقسیم است، نه میانگین‌گیری از نسبت‌های تک‌تک نشانه‌ها. این انتخاب، پاسخ به یک اشکال ناپایداری واقعی است که در مراحل اولیهٔ توسعهٔ این پروژه مشاهده شد: با فرمول میانگین نسبت‌ها، وجود حتی یک نشانه با نُرم فعال‌سازی نزدیک به صفر در یک دسته می‌توانست جملهٔ به‌شدت بزرگ و نامتناسبی در میانگین تولید کند و برای یک گام، کل آموزش را ناپایدار سازد؛ فرمول تجمیعی رابطهٔ ۱.۳، در برابر چنین دورافتاده‌هایی مقاوم است، چون سهم یک نشانهٔ منفرد در مجموع مخرج (نه در یک تقسیم مجزا) گم می‌شود. در پیاده‌سازی عملی، برای پایداری عددی بیشتر، یک ثابت کوچک به مخرج افزوده و خروجی نهایی از بالا کران‌دار می‌شود؛ مقادیر دقیق این دو ثابت در پیوست «الف» فهرست شده‌اند.

سنجهٔ مکملی که در فصل چهارم برای پایش این خطا در طول آموزش گزارش می‌شود، واریانس تبیین‌شدهٔ بازسازی است و به‌سادگی برابر با $1 - \mathcal{L}_{\text{recon}}$ تعریف می‌شود.

۶.۳ تابع هزینه

تابع هزینهٔ کلی هر گام آموزشی، مجموع چهار جزئی است که در بخش ۲.۳ معرفی شدند:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{lm}} + \mathcal{L}_{\text{recon}}^{\text{wiki}} + \lambda \left(\mathcal{L}_{\text{inv}} + \mathcal{L}_{\text{recon}}^{\text{paws}} \right) \tag{۲.۳}$$

که در آن $\mathcal{L}_{\text{lm}}$ هزینهٔ آنتروپی متقاطع استاندارد زبان‌مدل‌سازی روی دستهٔ WikiText است، $\mathcal{L}_{\text{recon}}^{\text{wiki}}$ منظم‌ساز بازسازی رابطهٔ ۱.۳ محاسبه‌شده روی فعال‌سازی‌های همان دستهٔ WikiText در لایه(های) هدف است، $\mathcal{L}_{\text{inv}}$

تابع هزینهٔ ناوردایی روی دستهٔ PAWS است، و $\mathcal{L}_{\text{recon}}^{\text{paws}}$ همان منظم‌ساز بازسازی است، این‌بار محاسبه‌شده روی فعال‌سازی‌های دستهٔ PAWS. نکتهٔ قابل‌توجه در این فرمول، عدم‌تقارن وزن‌دهی است: ضریب λ تنها روی جزء متمرکز بر PAWS (هم تابع هزینهٔ ناوردایی و هم منظم‌ساز بازسازی متناظر با آن) اعمال می‌شود، درحالی‌که مسیر متمرکز بر WikiText همواره با وزن ثابت یک در تابع هزینه حاضر است. پیامد این عدم‌تقارن آن است که با افزایش λ، وزن نسبی مسیر نگه‌دارندهٔ سلامت عمومی (زبان‌مدل‌سازی و بازسازی WikiText) در برابر مسیر متمرکز بر PAWS کاهش می‌یابد؛ در فصل چهارم (بخش ۴.۴) نشان داده می‌شود این عدم‌تقارن، تبیین محتملی برای هزینهٔ پایداری‌ای است که در وزن‌های بالای λ مشاهده می‌شود.

۱.۶.۳ تابع هزینهٔ ناوردایی

برای محاسبهٔ $\mathcal{L}_{\text{inv}}$، ابتدا از هر جمله در دستهٔ PAWS یک بردار تکی ساخته می‌شود: فعال‌سازی هر نشانهٔ آن جمله در لایهٔ هدف گرفته می‌شود و-بسته به شرط آزمایشی-یا مستقیماً میانگین‌گیری می‌شود (فضای خام)، یا نخست از میان $\text{Enc}(\cdot)$ عبور داده شده و سپس میانگین‌گیری می‌شود (فضای SAE؛ یعنی رمزگذاری پیش از تجمیع، نه برعکس، تا ورودی خودرمزگذار همواره در توزیعی بماند که برای آن آموزش دیده است). برای یک دستهٔ B جفت هم‌معنی $\{(a_i, b_i)\}_{i=1}^{B}$ و B جفت ناهم‌معنی $\{(a'_i, b'_i)\}_{i=1}^{B}$، شباهت کسینوسی هر جفت محاسبه می‌شود: $s_i^{\text{same}} = \cos(z_{a_i}, z_{b_i})$ و $s_i^{\text{diff}} = \cos(z_{a'_i}, z_{b'_i})$، که در آن z بردار تجمیع‌شده (خام یا SAE) است.

این $2B$ مقدار شباهت، با یک مقیاس آموختنی γ و یک بایاس آموختنی β به لوجیت تبدیل و با تابع هزینهٔ آنتروپی متقاطع دودویی زیر ترکیب می‌شوند:

$$\mathcal{L}_{\text{bce}} = -\frac{1}{2B}\left[\sum_{i=1}^{B}\log\sigma(\gamma s_i^{\text{same}} + \beta) + \sum_{i=1}^{B}\log\left(1 - \sigma(\gamma s_i^{\text{diff}} + \beta)\right)\right] \tag{۳.۳}$$

با σ تابع سیگموید. این صورت‌بندی-که این پایان‌نامه از آن با نام «BCE کسینوسی مقیاس‌پذیر» یاد می‌کند- جایگزین یک تابع هزینهٔ hinge با حاشیهٔ ثابت است: به‌جای تعریف دستی یک آستانهٔ جداکنندهٔ ثابت میان جفت‌های هم‌معنی و ناهم‌معنی، مقیاس و بایاس در حین آموزش یاد گرفته می‌شوند و مرز جداکننده را خودشان تطبیق می‌دهند. در پیاده‌سازی عملی، مقیاس γ از بالا کران‌دار می‌شود تا از یک راه میان‌بُر بی‌ربط به هدف اصلی جلوگیری شود: بدون این کران، مدل می‌تواند به‌جای دورترکردن واقعی بازنمایی‌ها، صرفاً γ را به‌طور نامحدود بزرگ کند تا شیب سیگموید حول هر جدایی موجود-هرچند ناچیز-تیزتر و در نتیجه، تابع هزینه کوچک‌تر شود؛

مقدار دقیق این کران در پیوست «الف» آمده است.

برای شرط C4 (بخش ۷.۳)، یک جزء مکمل اختیاری نیز-تنها برای جفت‌های هم‌معنی و تنها در فضای SAE-افزوده می‌شود: تقریب نرم و مشتق‌پذیر فاصلهٔ همپوشانی تکیه‌گاه[۷] (نسخهٔ نرم‌شدهٔ سنجهٔ دایس[۸]):

$$\mathcal{L}_{\text{support}} = ۱ - \frac{۲ \sum_j \min(z_{a,j}, z_{b,j})}{\sum_j z_{a,j} + \sum_j z_{b,j}} \tag{۴.۳}$$

که در آن j بر روی بُعدهای کد SAE اندیس می‌زند (کدها به‌دلیل معماری ReLU-پایه، نامنفی هستند). این جزء، برخلاف جزء BCE که تنها بر راستای بردارها (از طریق شباهت کسینوسی) حساس است، مستقیماً به هم‌پوشانی مجموعهٔ ویژگی‌های فعال در دو جمله حساس است: دو کد پراکنده می‌توانند شباهت کسینوسی بالایی داشته باشند درحالی‌که مجموعهٔ ویژگی‌های فعالشان تفاوت محسوسی دارد؛ جزء حمایتی برای سخت‌گیرانه‌ترکردن معیار «هم‌معنی‌بودن» در فضای SAE افزوده شده است.

۷.۳ شرایط آزمایشی

برای امکان مقایسهٔ علّی-یعنی برای پاسخ‌دادن به این پرسش که آیا اثر مشاهده‌شده واقعاً از انتخاب فضای SAE ناشی می‌شود یا صرفاً از وجود هر نوع هدف ناوردایی-چهار شرط آزمایشی تعریف شده‌اند که تنها در یک یا دو مؤلفه با یکدیگر تفاوت دارند. جدول ۱.۳ این شرایط را خلاصه می‌کند.

جدول ۱.۳: شرایط آزمایشی. ستون «فضا» فضایی را نشان می‌دهد که تابع هزینهٔ ناوردایی در آن محاسبه می‌شود.

شرط	توضیح	فضا	BCE	جزء حمایتی
C1 (کنترل)	بدون تابع هزینهٔ ناوردایی	—	—	—
C2	ناوردایی در فضای خام	خام	✓	—
C3	ناوردایی در فضای SAE	SAE	✓	—
C4	ناوردایی در فضای SAE + حمایت	SAE	✓	✓

شرط C1 به‌عنوان خط پایهٔ کنترلی عمل می‌کند: مدل تنها با هزینهٔ زبان‌مدل‌سازی (و منظم‌ساز بازسازی

[7] Support Overlap
[8] Dice

WikiText) ریزتنظیم می‌شود، بدون آنکه هیچ سیگنالی از PAWS ببیند. مقایسهٔ C1 با سه شرط دیگر، امکان پاسخ به این پرسش را می‌دهد که آیا صرف ریزتنظیم‌کردن مدل-بدون هیچ هدف مشخصی دربارهٔ جداسازی معنایی-به‌خودی‌خود می‌تواند جداسازی هم‌معنی/ناهم‌معنی را تغییر دهد. مقایسهٔ C2 با C3 مستقیماً فرضیهٔ محوری این پایان‌نامه را می‌آزماید: با ثابت‌نگه‌داشتن همهٔ اجزای دیگر تابع هزینه، تنها تفاوت این دو شرط، فضایی است که در آن شباهت کسینوسی محاسبه می‌شود. مقایسهٔ C3 با C4 نیز اثر جزء حمایتی تکمیلی را، مستقل از جزء اصلی BCE، می‌سنجد.

۸.۳ طرح آزمایش‌های شبکه‌ای

فراتر از چهار شرط بالا، دو ابرپارامتر دیگر نیز به‌طور سیستماتیک تغییر داده شده‌اند:

وزن تابع هزینهٔ ناوردایی (λ). برای هر یک از سه شرط دارای تابع هزینهٔ ناوردایی (C2، C3، C4)، پنج مقدار λ -از بسیار کوچک تا نسبتاً بزرگ-آزموده شده است؛ مقادیر دقیق در پیوست «الف» آمده‌اند. شرط C1 از این ابرپارامتر مستقل است (تنها یک بار اجرا می‌شود).

لایه(های) هدف. تابع هزینهٔ ناوردایی و منظم‌ساز بازسازی PAWS می‌توانند هم‌زمان روی یک یا چند لایه اعمال شوند (در این حالت، رابطهٔ ۲.۳ روی مجموع لایه‌های هدف جمع‌بندی می‌شود). ده حالت متفاوت برای این انتخاب آزموده شده‌اند: شش تک‌لایه (تمام لایه‌های این مدل) و چهار ترکیب چندلایهٔ متوالی از لایه‌های میانی-به-بعد؛ فهرست دقیق در پیوست «الف» آمده است.

مجموع این دو محور آزمایش‌های شبکه‌ای-در هر یک از ده حالت انتخاب لایه، سه شرط در پنج مقدار λ به‌علاوهٔ یک اجرای C1-در مجموع ۱۶۰ اجرای ریزتنظیم مستقل، به‌علاوهٔ یک ارزیابی خط پایه روی مدل پیش‌آموزش‌دیدهٔ بدون ریزتنظیم، تولید می‌کند. جدول کامل این شبکهٔ آزمایشی در پیوست «الف» آمده است.

۹.۳ معیارهای ارزیابی

پس از هر اجرای آموزش، مدل حاصل بر روی شکاف آزمون PAWS و در تمام لایه‌های مدل-نه فقط لایه(های) هدف آموزش-ارزیابی می‌شود. برای هر لایه و هر یک از دو فضا (خام و SAE)، معیار اصلی

گزارش‌شده، AUROC (سطح زیر منحنی مشخصهٔ عملکرد گیرنده) [۱۰] است: با در نظرگرفتن فاصلهٔ کسینوسی $1 - \cos(z_a, z_b)$ هر جفت به‌عنوان سنجهٔ تفکیک‌کننده، AUROC احتمال آن است که یک جفت ناهم‌معنی تصادفی، فاصلهٔ بزرگ‌تری از یک جفت هم‌معنی تصادفی داشته باشد؛ مقدار ۰٫۵ معادل حدس تصادفی و مقدار ۱ معادل تفکیک کامل است. تفاوت $\Delta_{\text{AUROC}} = \text{AUROC}_{\text{SAE}} - \text{AUROC}_{\text{raw}}$ در هر لایه، به‌طور مجزا نیز گزارش می‌شود تا مشخص شود در کدام لایه، فضای SAE نسبت به فضای خام، تفکیک‌کنندهٔ بهتری است یا نه.

در کنار AUROC، دو معیار مکمل زیر نیز محاسبه می‌شوند:

سرگشتگی زبان‌مدل‌سازی[۹]**:** سرگشتگی مدل روی شکاف اعتبارسنجی WikiText، در هر نقطهٔ بازرسی، به‌عنوان سنجهٔ سلامت عمومی زبان‌مدل‌سازی پایش می‌شود؛ افزایش محسوس این سنجه نسبت به شرط کنترلی، نشانهٔ آن است که ریزتنظیم، به بهای افت کیفیت زبانی مدل، به هدف ناوردایی رسیده است.

واریانس تبیین‌شده‌بازسازی: همان کمیت معرفی‌شده در بخش ۱.۵.۳، محاسبه‌شده روی مخلوط فعال‌سازی‌های PAWS و WikiText در هر نقطهٔ بازرسی؛ این سنجه، معیار اصلی پایش سلامت فرض «خودرمزگذار ثابت همچنان معتبر» است.

۱۰.۳ جزئیات پیاده‌سازی

تمام آزمایش‌ها با کتابخانه‌های PyTorch، HuggingFace Transformers و PEFT (برای لورا)، و SAELens [۳] (برای بارگذاری خودرمزگذارهای از پیش‌آموزش‌دیده، با قلاب‌گذاری در نقاط سازگار با قراردادهای TransformerLens [۲۲]) پیاده‌سازی شده‌اند. هر پیکربندی (ترکیب شرط، λ، و لایهٔ هدف) به‌طور مستقل و از ابتدا، با بهینه‌ساز AdamW و بریدن نرم گرادیان[۱۰] روی مجموع پارامترهای قابل‌آموزش اجرا شده است. هر تعدادی گام ثابت، معیارهای بخش ۹.۳ روی شکاف اعتبارسنجی محاسبه و ثبت می‌شوند. جدول کامل ابرپارامترها-شامل نرخ یادگیری، تعداد گام‌های آموزش، اندازهٔ دسته‌ها، و مقادیر دقیق ثابت‌های پایداری عددی اشاره‌شده در بخش‌های ۵.۳ و ۶.۳-در پیوست «الف» آمده است.

[10] Gradient Clipping

فصل ۴

نتایج

۱.۴ مقدمه

این فصل نتایج تجربی حاصل از ۱۶۰ اجرای ریزتنظیم مستقل (بخش ۸.۳) به‌علاوهٔ ارزیابی خط پایهٔ مدل پیش‌آموزش‌دیده را گزارش می‌کند. ترتیب ارائه به این صورت است: ابتدا اثر شرط آزمایشی و وزن λ (بخش ۲.۴)، پس‌ازآن اثر انتخاب لایهٔ هدف (بخش ۳.۴)، هزینهٔ این بهبود از نظر سرگشتگی زبانی و اعتبار خودرمزگذار (بخش ۴.۴)، و سرانجام معرفی یک پیکربندی توصیه‌شده بر مبنای مصالحهٔ میان این دو (بخش ۵.۴).

۲.۴ اثر شرط آزمایشی و وزن ناوردایی

برای هر یک از ۱۶۰ اجرا، بهبود AUROC در فضای SAE نسبت به خط پایه، در همان لایه(ها)یی که هدف تابع هزینهٔ ناوردایی بوده‌اند، محاسبه شد. جدول ۱.۴ میانگین این بهبود را-با میانگین‌گیری روی تمام ده حالت انتخاب لایه و (برای شرایط دارای λ) روی هر پنج مقدار آن-برای هر شرط خلاصه می‌کند.

سه یافتهٔ این جدول، ستون فقرات اصلی نتایج این پایان‌نامه‌اند. نخست، C1-شرط کنترلی که هیچ سیگنالی از PAWS دریافت نمی‌کند-میانگین بهبودی تقریباً صفر (و اندکی منفی) دارد؛ این تأیید می‌کند که صرف ریزتنظیم‌کردن مدل روی WikiText، به‌خودی‌خود، جداسازی هم‌معنی/ناهم‌معنی را بهبود نمی‌بخشد. دوم، C2-اعمال همان تابع هزینهٔ ناوردایی، اما در فضای خام-نیز به‌طور میانگین تفاوت معناداری با خط پایه ندارد، هرچند واریانس آن به‌مراتب بیشتر از C1 است: اعمال این هدف مستقیماً در فضای خام گاهی کمی کمک می‌کند و گاهی کمی ضرر

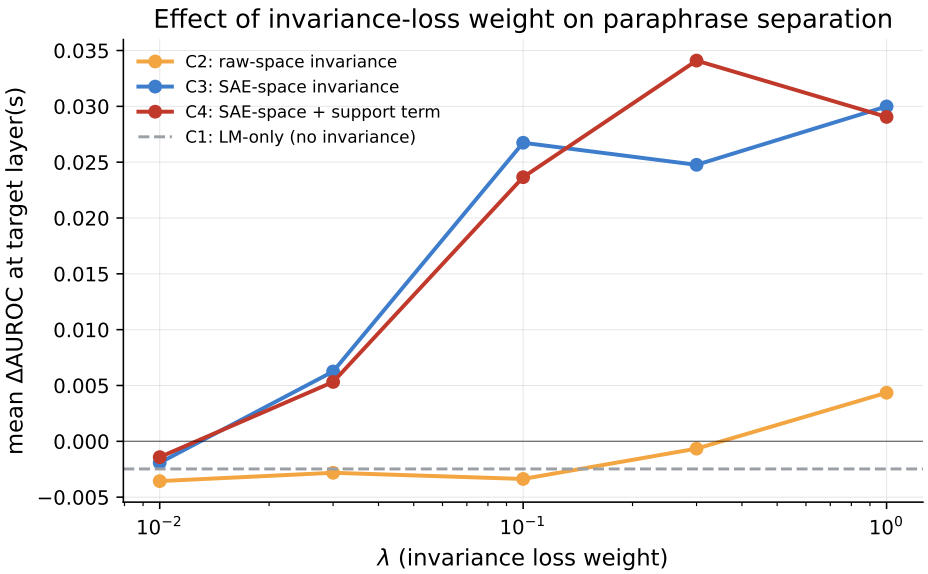
جدول ۱.۴: میانگین و بازهٔ بهبود AUROC نسبت به خط پایه، در لایه(های) هدف، به تفکیک شرط آزمایشی.

شرط	میانگین بهبود	کمینه	بیشینه
C1 (کنترل، بدون ناوردایی)	−۰٫۰۰۱۴	−۰٫۰۰۶۷	+۰٫۰۰۱۲
C2 (ناوردایی، فضای خام)	−۰٫۰۰۰۸	−۰٫۰۲۰۴	+۰٫۰۲۵۳
C3 (ناوردایی، فضای SAE)	+۰٫۰۱۲۹	−۰٫۰۳۴۷	+۰٫۰۶۹۴
C4 (فضای SAE + حمایت)	+۰٫۰۱۵۰	−۰٫۰۳۳۶	+۰٫۰۶۷۸

می‌رساند، بدون الگویی قابل‌اتکا. سوم، و مهم‌ترین یافته: تنها با انتقال همین تابع هزینه به فضای SAE (شرایط C3 و C4) میانگین بهبود به‌طور قابل‌توجهی مثبت می‌شود، و بیشینهٔ بهبود در بهترین پیکربندی‌ها به نزدیک ۰٫۰۷ می‌رسد. این تباین سه‌گانه-کنترل خنثی، فضای خام بی‌اثر، فضای SAE مؤثر-شاهد تجربی اصلی این پایان‌نامه به نفع فرضیهٔ محوری آن است: خودرمزگذار پراکنده، فضای مؤثرتری برای شکل‌دادن این نوع بازنمایی فراهم می‌کند. جزء حمایتی تکمیلی C4 نسبت به C3 اندکی بهتر عمل می‌کند، هرچند این تفاوت در مقایسه با شکاف اصلی میان فضای خام و فضای SAE، کوچک است. مقادیر بیشینهٔ جدول بالا-که همگی در وزن λ بزرگ به دست می‌آیند-را باید با احتیاط خواند: همان‌طور که در بخش ۴.۴ نشان داده می‌شود، این مقادیر با هزینه‌ای در پایداری آموزش همراه‌اند که در همین جدول دیده نمی‌شود.

شکل ۱.۴ همین دادگان را به‌تفکیک وزن λ نشان می‌دهد.

الگوی این نمودار برای C3 و C4 تقریباً یکسان است: در $\lambda = ۰٫۰۱$، بهبود عملاً صفر یا منفی است-یعنی سیگنال ناوردایی در برابر هزینهٔ زبان‌مدل‌سازی چنان ضعیف است که عملاً بی‌اثر می‌ماند. با رسیدن λ به ۰٫۱، جهش محسوسی در بهبود رخ می‌دهد، و از آن پس، افزایش بیشتر λ تا ۱٫۰ سود نسبتاً کمی به همراه دارد. در مقابل، برای C2 (فضای خام)، حتی در $\lambda = ۱٫۰$ بهبود میانگین ناچیز باقی می‌ماند. جدول کامل این ارقام، به تفکیک هر مقدار λ، در پیوست «ب» آمده است؛ همان‌طور که در بخش ۴.۴ نشان داده خواهد شد، رفتن به سمت λ بزرگ برای کسب همین سود نهایی، هزینه‌ای در پایداری آموزش دارد که ارزش آن را باید در کنار اندازهٔ بهبود سنجید.



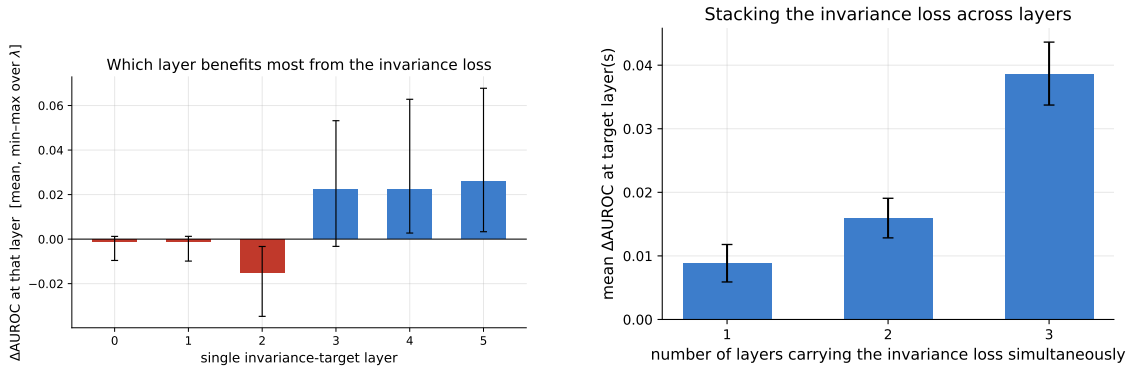
شکل ۱.۴: میانگین بهبود AUROC در لایه(های) هدف، بر حسب وزن تابع هزینهٔ ناوردایی λ (میانگین روی هر ده حالت انتخاب لایه). خط افقی، سطح شرط C1 (فاقد λ) را نشان می‌دهد.

۳.۴ اثر انتخاب لایهٔ هدف و نمایهٔ کامل عمق

محور دوم آزمایش‌های شبکه‌ای، انتخاب لایه(های) هدف بود. شکل ۲.۴ دو جنبهٔ این محور را نشان می‌دهد: تأثیر تعداد لایه‌های هم‌زمان و تأثیر اینکه کدام لایهٔ منفرد انتخاب شده، هر دو با میانگین‌گیری روی شرایط C3 و C4 و تمام مقادیر λ.

نمودار سمت چپ الگویی غیریکنواخت اما معنادار را آشکار می‌کند: لایه‌های نزدیک به ورودی تقریباً بی‌اثرند؛ لایهٔ دوم (از شش لایهٔ مدل) به‌طور سیستماتیک زیان‌آور است (بدترین مورد منفرد کل این پایان‌نامه، دقیقاً در همین لایه رخ داده است)؛ و از حدود نیمهٔ عمق مدل به بعد، بهبود به‌طور پیوسته مثبت و رو به افزایش است. به‌عبارت دیگر، اعمال هدف ناوردایی روی لایه‌های ابتدایی این مدل کوچک، در بهترین حالت بی‌فایده و در بدترین حالت مخرب است؛ درحالی‌که همین هدف، وقتی روی نیمهٔ دوم عمق مدل اعمال شود، به‌طور پایدار سودمند است. این الگو با این تعبیر رایج در ادبیات تفسیرپذیری سازگار است که لایه‌های ابتدایی یک مدل زبانی عمدتاً بازنمایی سطحی و واژگانی می‌سازند، درحالی‌که بازنمایی معنایی و ترکیبی-که برای تشخیص تفاوت ظریف میان جفت‌جمله‌های PAWS لازم است-در لایه‌های عمیق‌تر شکل می‌گیرد.

نمودار سمت راست نشان می‌دهد که اثر اعمال هم‌زمان تابع هزینه روی چند لایه، نه‌تنها جمع‌شونده بلکه



شکل ۲.۴: چپ: میانگین بهبود AUROC بر حسب اینکه کدام لایهٔ منفرد هدف تابع هزینهٔ ناوردایی بوده (میله‌های خطا، بازهٔ کمینه تا بیشینه روی λها را نشان می‌دهند). راست: میانگین بهبود بر حسب تعداد لایه‌هایی که هم‌زمان تحت تابع هزینهٔ ناوردایی قرار گرفته‌اند. هر دو نمودار، میانگین شرایط C3 و C4 است.

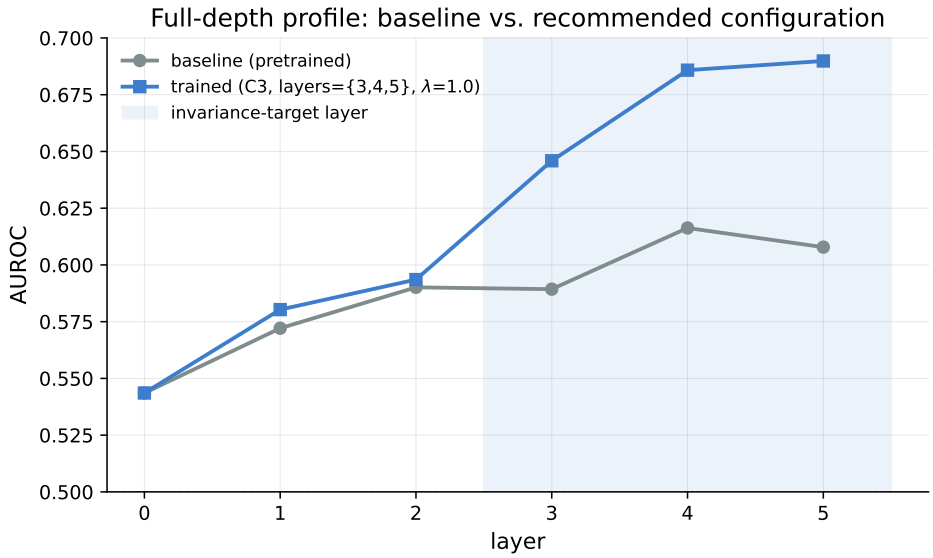
فراجمع‌شونده[1] است: میانگین بهبود برای سه لایهٔ هم‌زمان، به‌وضوح بیش از سه برابر میانگین بهبود یک لایهٔ منفرد است. تعبیر محتمل این است که چون جریان باقیمانده در معماری ترنسفورمر جمعی[2] است، اعمال هم‌زمان هدف روی چند لایهٔ متوالی، مسیرهای بیشتری برای شکل‌دادن دوبارهٔ محاسبات درونی مدل در جهت هدف موردنظر در اختیار بهینه‌سازی می‌گذارد.

شکل ۳.۴ نمایهٔ کامل عمق پیکربندی با شرط C3 با هدف‌گیری هم‌زمان لایه‌های $\{۳, ۴, ۵\}$ و $\lambda = ۱/۰$ را در برابر خط پایه نشان می‌دهد.

نکتهٔ مهم این نمایه، رفتار آن در لایه‌های غیرهدف (۰ تا ۲) است: بهبود در این لایه‌ها عملاً ناچیز اما مثبت است ($+۰/۰۰$ در لایهٔ ۰ تا $+۰/۰۰۸$ در لایهٔ ۱)، نه منفی. به‌عبارت دیگر، فشاردادن بازنمایی لایه‌های عمیق در جهت جداسازی بهتر هم‌معنی/ناهم‌معنی، به‌بهای تخریب بازنمایی لایه‌های کم‌عمق‌تر تمام نشده است؛ این تعمیم‌ناپذیری خوش‌خیم (نه مثبت و نه منفی محسوس) نشان می‌دهد اثر آموزش، تا حد زیادی موضعی و محدود به همان لایه‌هایی است که مستقیماً هدف قرار گرفته‌اند.

الگوی مشابهی، با جزئیات بیشتر، در بهترین پیکربندی تک‌لایه (لایهٔ ۵، شرط C4، $\lambda = ۰/۳$، با بهبود $+۰/۰۶۸$ در همان لایه) دیده می‌شود: بهبود در لایه‌های ۰ تا ۳ عملاً صفر است (کمتر از $۰/۰۰۱$ در قدرمطلق)، اما در لایهٔ ۴-که مستقیماً هدف قرار نگرفته، ولی بلافاصله پیش از لایهٔ هدف قرار دارد-بهبود قابل‌توجه $+۰/۰۴۳$ ثبت شده است. این «نشت» بهبود به‌سمت عقب، با معماری جریان باقیماندهٔ ترنسفورمر سازگار است: فعال‌سازی لایهٔ ۵، تابعی مستقیم از فعال‌سازی لایهٔ ۴ است، و بنابراین، هر تغییری که وزن‌های لورا برای دورکردن بازنمایی لایهٔ ۵ اعمال می‌کنند، الزاماً بازنمایی لایهٔ ۴ (که ورودی لایهٔ ۵ را می‌سازد) را نیز تحت‌تأثیر قرار می‌دهد. این

[1] Super-additive
[2] Additive



شکل ۳.۴: نمایهٔ کامل AUROC در تمام شش لایه، برای خط پایه در برابر بهترین پیکربندی (C3، لایه‌های هدف $\{۳, ۴, ۵\}$، $\lambda = ۱/۰$). ناحیهٔ سایه‌خورده، لایه‌های هدف را نشان می‌دهد.

یافته پیشنهاد می‌کند که تعمیم اثر این روش، بیشتر «رو به عقب» (به لایه‌های نزدیک‌تر به ورودی که خروجی‌شان مستقیماً وارد لایهٔ هدف می‌شود) رخ می‌دهد تا «رو به جلو».

۴.۴ هزینهٔ پایداری: سرگشتگی و اعتبار خودرمزگذار

نتایج دو بخش پیشین، عمداً تنها بهبود نهایی AUROC را گزارش کردند. اما این بهبود، رایگان به دست نیامده است. این بخش دو سنجهٔ سلامت جانبی-سرگشتگی زبانی و اعتبار بازسازی خودرمزگذار-را در سرتاسر شبکهٔ آزمایشی بررسی می‌کند.

۱.۴.۴ سرگشتگی زبان‌مدل‌سازی

جدول ۲.۴ میانگین سرگشتگی اعتبارسنجی WikiText را در گام پایانی آموزش، به‌تفکیک شرط و λ، نشان می‌دهد.

الگوی این جدول واضح است: تا $\lambda = ۰/۱$، سرگشتگی در تمام شرایط عملاً دست‌نخورده می‌ماند (در محدودهٔ 59 تا 60، تقریباً برابر با شرط کنترلی). از $\lambda = ۰/۳$ به بعد، شرایط C3 و C4-یعنی دقیقاً همان شرایطی

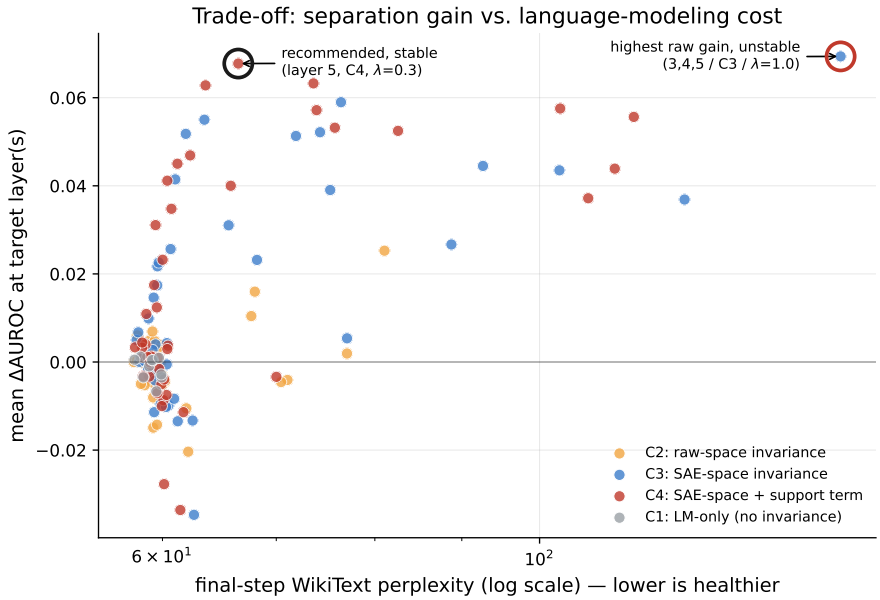
جدول ۲.۴: میانگین سرگشتگی WikiText در گام پایانی آموزش، به تفکیک شرط و λ. برای مقایسه، شرط C1 (بدون هیچ هدف ناوردایی) به سرگشتگی ۵۹٫۱ می‌رسد.

λ	C2 (خام)	C3 (SAE)	C4 (SAE+حمایت)
۰٫۰۱	۵۹٫۰	۵۹٫۲	۵۹٫۱
۰٫۰۳	۵۹٫۱	۵۹٫۱	۵۹٫۴
۰٫۱۰	۵۹٫۱	۶۰٫۲	۵۹٫۹
۰٫۳۰	۵۹٫۵	۶۵٫۹	۶۴٫۴
۱٫۰۰	۶۷٫۵	۸۹٫۰	۸۴٫۴

که در فضای SAE عمل می‌کنند-شروع به افزایش محسوس سرگشتگی می‌کنند، و در $\lambda = ۱٫۰$، این افزایش به بیش از یک‌ونیم برابر (برای C4) تا نزدیک به سه برابر (برای C3) مقدار کنترلی می‌رسد. شرط C2 (فضای خام) در برابر این اثر تا حد زیادی مصون است و تنها در $\lambda = ۱٫۰$ افزایش ملایمی نشان می‌دهد. این عدم‌تقارن میان C2 و C4/C3 با فرمول تابع هزینهٔ بخش ۶.۳ سازگار است: در شرایط C3 و C4، همان لایه‌ای که هدف تابع هزینهٔ ناوردایی است، همزمان ورودی خودرمزگذار نیز هست، و کشیده‌شدن این لایه در جهت جداسازی هم‌معنی/ناهم‌معنی، با حفظ سلامت عمومی زبانی-که به‌طور جداگانه و با وزن ثابت در تابع هزینه حضور دارد-به رقابت می‌افتد.

برای دیدن این مصالحه در سطح کل شبکهٔ آزمایشی-نه فقط میانگین‌های جدول بالا-شکل ۴.۴ بهبود AUROC هر یک از ۱۶۰ اجرا را در برابر سرگشتگی نهایی همان اجرا رسم می‌کند.

این نمودار، همان الگویی را که در سه بخش پیشین به‌صورت میانگین دیده شد، در سطح تک‌تک اجراها آشکار می‌کند: ابر نقاط خاکستری و نارنجی (C1 و C2) تقریباً همگی در نوار باریکی از سرگشتگی پایین و بهبود نزدیک به صفر متمرکزند. ابر نقاط آبی و قرمز (C3 و C4) اما، یک الگوی روشن نشان می‌دهند: با دورشدن به سمت راست نمودار (سرگشتگی بالاتر)، بهبود نیز افزایش می‌یابد، اما این افزایش نزولی است-یعنی شکل ابر نقاط، بیشتر یک سطح صعودی روبه‌کاهش است تا یک خط راست. پیکربندی توصیه‌شده (دایرهٔ مشکی) دقیقاً در ناحیه‌ای از این ابر قرار دارد که به لبهٔ سمت چپ آن (سرگشتگی پایین) نزدیک است اما هنوز بهبودی نزدیک به بیشینهٔ کل نمودار به دست می‌دهد؛ پیکربندی با بیشترین بهبود خام (دایرهٔ قرمز) در انتهای دور راست همین ابر قرار دارد، جایی که برای رسیدن به کمترین مقدار اضافی بهبود، باید بهای سرگشتگی‌ای پرداخت که چند برابر بزرگ‌تر است. به‌عبارت دیگر، شکل ۴.۴ به‌روشنی نشان می‌دهد که پیمودن کامل این منحنی تا انتهای آن، ارزش اقتصادی نزولی دارد: بخش عمدهٔ بهبود، با بخش کوچکی از هزینهٔ کل سرگشتگی به دست می‌آید.



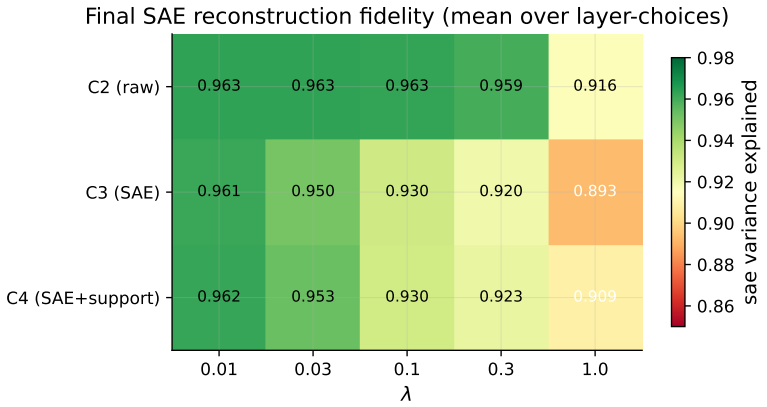
شکل ۴.۴: مصالحهٔ میان بهبود AUROC و سرگشتگی نهایی WikiText، برای هر یک از ۱۶۰ اجرا. محور افقی لگاریتمی است. دایرهٔ توخالی مشکی، پیکربندی توصیه‌شده را نشان می‌دهد؛ دایرهٔ توخالی قرمز، پیکربندی با بیشترین بهبود خام را.

۲.۴.۴ اعتبار بازسازی خودرمزگذار

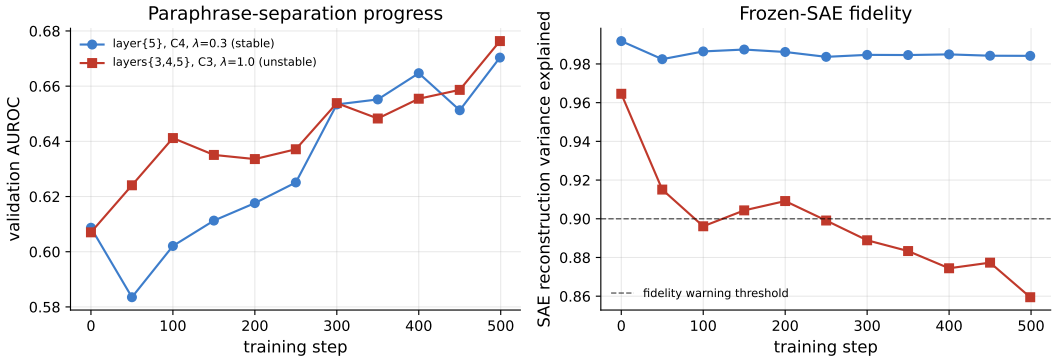
شکل ۵.۴ میانگین واریانس تبیین‌شدهٔ بازسازی را در گام پایانی آموزش، به‌تفکیک شرط و λ نشان می‌دهد. الگوی این شکل، الگوی جدول سرگشتگی را بازتاب می‌دهد: تا $\lambda = ۰/۱$، واریانس تبیین‌شده در تمام شرایط بالای ٪۹۵ باقی می‌ماند؛ از $\lambda = ۰/۳$ به بعد، شرایط C3 و C4 افت محسوسی نشان می‌دهند (به ترتیب ٪۹۲/۰ و ٪۹۲/۳ در $\lambda = ۰/۳$)، و در $\lambda = ۱/۰$ شرط C3 از آستانهٔ هشدار عبور می‌کند (٪۸۹/۳). در سطح کل ۱۶۰ اجرا، ٪۱۸/۸ از آن‌ها (عمدتاً شرایط C4/C3 با $\lambda \geq ۰/۳$) با واریانس تبیین‌شدهٔ کمتر از آستانهٔ هشدار به پایان رسیده‌اند.

۳.۴.۴ نمونه‌ای از مصالحه: دو اجرای متضاد

برای مشاهدهٔ ملموس این مصالحه در طول زمان، شکل ۶.۴ دو سنجه را در طول آموزش، برای دو اجرا مقایسه می‌کند: پیکربندی توصیه‌شدهٔ این پایان‌نامه (لایهٔ هدف منفرد پنجم، شرط C4، $\lambda = ۰/۳$؛ معرفی کامل در بخش ۵.۴)، و یک پیکربندی تهاجمی‌تر با بهبود خام اندکی بالاتر (لایه‌های هدف سوم تا پنجم به‌طور هم‌زمان، شرط C3، $\lambda = ۱/۰$).



شکل ۵.۴: میانگین واریانس تبیین‌شدهٔ بازسازی خودرمزگذار در گام پایانی آموزش، به‌تفکیک شرط و λ (میانگین روی هر ده حالت انتخاب لایه).



شکل ۶.۴: پویایی آموزش برای پیکربندی توصیه‌شده (آبی) در برابر یک پیکربندی تهاجمی‌تر جایگزین با $\lambda = ۱/۰$ و سه لایهٔ هدف هم‌زمان (قرمز). چپ: AUROC اعتبارسنجی PAWS. راست: واریانس تبیین‌شدهٔ بازسازی خودرمزگذار.

نمودار سمت چپ نشان می‌دهد که این دو پیکربندی به AUROC نهایی تقریباً یکسانی می‌رسند. نمودار سمت راست پیامد این تفاوت را برای اعتبار خودرمزگذار نشان می‌دهد: پیکربندی تهاجمی‌تر، در طول آموزش، پیوسته واریانس تبیین‌شدهٔ پایین‌تری دارد.

نتیجه‌گیری این مقایسه ساده است: دو پیکربندی به جداسازی تقریباً یکسانی می‌رسند، اما یکی از آن‌ها این کار را با هزینهٔ به‌مراتب کمتری-هم برای سلامت زبانی مدل و هم برای اعتبار ابزار سنجش-انجام می‌دهد. همین مشاهده، مبنای انتخاب پیکربندی توصیه‌شدهٔ بخش بعدی است.

۵.۴ پیکربندی توصیه‌شده

با درنظرگرفتن هر سه سنجه-بهبود AUROC، سرگشتگی زبانی، و اعتبار بازسازی-پیکربندی توصیه‌شده، C4 با هدف‌گیری لایهٔ پنجم (تنها) و $\lambda = ۰/۳$ است. این پیکربندی به بهبود ۰/۰۶۸ در AUROC فضای SAE می‌رسد-عملاً برابر با بالاترین بهبود خام کل شبکهٔ آزمایشی (۰/۰۶۹، متعلق به یک پیکربندی سه‌لایهٔ هم‌زمان با $\lambda = ۱/۰$)-درحالی‌که سرگشتگی نهایی‌اش (۶۶/۵) تنها حدود ٪۱۳ بالاتر از شرط کنترلی (۵۹/۱) است و واریانس تبیین‌شدهٔ بازسازی‌اش (٪۹۸/۴) به‌مراتب بالاتر از آستانهٔ هشدار باقی می‌ماند؛ در مقابل، پیکربندی سه‌لایهٔ $\lambda = ۱/۰$ سرگشتگی‌ای معادل ۱۵۰/۳ (بیش از دو ونیم برابر کنترل) و واریانس تبیین‌شده‌ای معادل ٪۸۶/۰ (زیر آستانهٔ هشدار) دارد. به‌عبارت دیگر، رفتن از $\lambda = ۰/۳$ به $\lambda = ۱/۰$ (به‌همراه افزودن دو لایهٔ هدف دیگر) تنها ۰/۰۰۱ واحد بهبود اضافی در AUROC به همراه دارد، اما به بهای بیش از دو برابرشدن سرگشتگی و سقوط اعتبار خودرمزگذار به زیر آستانهٔ هشدار تمام می‌شود؛ مصالحه‌ای که ارزش آن سود اندک را ندارد.

۶.۴ جمع‌بندی نتایج

یافته‌های این فصل را می‌توان در پاسخ به سه پرسش پژوهشی فصل اول این‌گونه خلاصه کرد. نخست، اعمال تابع هزینهٔ ناوردایی در فضای خودرمزگذار پراکنده، به‌طور پایدار و در سرتاسر شبکهٔ آزمایشی، جداسازی بهتری میان جفت‌جمله‌های هم‌معنی و ناهم‌معنی نسبت به اعمال همان تابع هزینه در فضای خام تولید می‌کند؛ شرط کنترلی فاقد هرگونه هدف ناوردایی، هیچ بهبودی نشان نمی‌دهد. دوم، این جداسازی به‌شدت به لایهٔ هدف (لایه‌های میانی-به-بعد، نه لایه‌های ابتدایی) و به وزن λ وابسته است، و اعمال هم‌زمان چند لایه اثری فراجمع‌شونده دارد. سوم، و مهم‌تر از نظر عملی: بالاترین بهبودهای خام-که همگی در λ بزرگ به دست می‌آیند- با هزینهٔ محسوسی در ثبات آموزش و در اعتبار خودرمزگذار همراه‌اند، درحالی‌که یک پیکربندی محافظه‌کارانه‌تر ($\lambda = ۰/۳$، تک‌لایه) تقریباً به همان بهبود می‌رسد بدون تحمیل این هزینه. فصل پنجم این یافته‌ها را در پرتو اهداف پژوهش جمع‌بندی و محدودیت‌ها و جهت‌های پژوهش آینده را بیان می‌کند.

فصل ۵

جمع‌بندی و نتیجه‌گیری

۱.۵ مروری بر پژوهش

این پایان‌نامه از یک مشاهدهٔ ساده آغاز شد: وقتی جفت‌جمله‌های مجموعه‌دادهٔ PAWS [۳۳] از یک مدل زبانی پیش‌آموزش‌دیده عبور داده می‌شوند، بازنمایی جفت‌های هم‌معنی و ناهم‌معنی، به‌رغم همپوشانی واژگانی تقریباً یکسان آن‌ها، به‌اندازهٔ کافی از هم متمایز نیست. این پایان‌نامه پرسید آیا می‌توان مدل را ریزتنظیم کرد تا این تمایز بهبود یابد، و اگر چنین است، آیا فراهم‌کردن سیگنال لازم برای این بهبود، در فضای نهان یک خودرمزگذار پراکندهٔ ثابت-به‌جای فضای خام جریان باقیمانده-مؤثرتر است. برای پاسخ به این پرسش، مدل Pythia-70m-deduped با تطبیق‌دهندهٔ لورا و یک تابع هزینهٔ ترکیبی (زبان‌مدل‌سازی + ناوردایی + منظم‌ساز بازسازی خودرمزگذار) ریزتنظیم شد، و در یک شبکهٔ آزمایشی متشکل از چهار شرط، پنج مقدار وزن ناوردایی، و ده حالت انتخاب لایهٔ هدف-در مجموع ۱۶۰ اجرای مستقل-مورد ارزیابی قرار گرفت.

۲.۵ یافته‌های اصلی

چهار یافتهٔ اصلی این پایان‌نامه، که با جزئیات در فصل چهارم ارائه شدند، به‌طور خلاصه از این قرارند:

۱. **برتری فضای SAE بر فضای خام.** اعمال تابع هزینهٔ ناوردایی در فضای خودرمزگذار پراکنده (شرایط C3 و C4)، به‌طور پایدار در سرتاسر شبکهٔ آزمایشی، جداسازی بهتری میان جفت‌های هم‌معنی و ناهم‌معنی

تولید کرد، درحالی‌که همان تابع هزینه در فضای خام (C2) و شرط کنترلی فاقد هرگونه هدف ناوردایی (C1) هیچ‌کدام بهبود میانگین قابل‌اتکایی نشان ندادند. این یافته، فرضیهٔ محوری پایان‌نامه را تأیید می‌کند: پراکنده‌سازی فضای بازنمایی، پیش از اعمال یک هدف تقابلی، آن هدف را مؤثرتر می‌کند.

۲. **وابستگی شدید به عمق لایه و وزن ناوردایی.** این بهبود، یکنواخت در سرتاسر عمق مدل رخ نمی‌دهد: لایه‌های ابتدایی تقریباً بی‌اثرند، لایهٔ دوم به‌طور سیستماتیک زیان‌آور است، و تنها از نیمهٔ عمق مدل به بعد، بهبود پایدار و رو به افزایش می‌شود. هدف‌گیری هم‌زمان چند لایه، اثری فراجمع‌شونده دارد. از نظر وزن ناوردایی نیز، آستانه‌ای مؤثر مشاهده شد که پیش از آن، سیگنال ناوردایی عملاً در برابر هزینهٔ زبان‌مدل‌سازی گم می‌شود.

۳. **مصالحه‌ای واقعی میان جداسازی و پایداری.** بالاترین سطوح بهبود خام-که همگی در بزرگ‌ترین وزن آزموده‌شده ($\lambda = ۱/۰$) به دست می‌آیند-با ناپایداری گذرا در سرگشتگی زبان‌مدل‌سازی و با افت محسوس اعتبار بازسازی خودرمزگذار همراه بودند؛ در حدود یک‌پنجم کل اجراها، این اعتبار به زیر آستانهٔ هشدار تعیین‌شده سقوط کرد. منظم‌ساز بازسازی، این هزینه را در بازهٔ λ پایین به‌طور کامل مهار کرد، اما در بازهٔ λ بالا-دقیقاً همان‌جا که بیشترین بهبود خام مشاهده می‌شود-تنها تا حدی مؤثر بود.

۴. **یک پیکربندی توصیه‌شده متعادل.** یک وزن میانه‌روتر ($\lambda = ۰/۳$) به بهبودی تقریباً برابر با بالاترین بهبود خام کل شبکهٔ آزمایشی می‌رسد، اما با سرگشتگی و اعتبار بازسازی‌ای که در محدودهٔ کاملاً قابل‌قبول باقی می‌مانند. این یافته پیشنهاد می‌کند که، دست‌کم برای این مدل و این وظیفه، رفتن به سمت بزرگ‌ترین وزن ممکن، انتخاب عاقلانه‌ای نیست.

۳.۵ نوآوری پژوهش

همان‌طور که در فصل اول و در بخش ۷.۲ بحث شد، نوآوری اصلی این پایان‌نامه، به‌کارگیری خودرمزگذار پراکنده-ابزاری که تاکنون عمدتاً برای تحلیل پس‌ازآموزش یا هدایت زمان استنتاج به کار رفته-به‌عنوان فضای هدف یک تابع هزینهٔ آموزشی است که مستقیماً وزن‌های مدل را تغییر می‌دهد. نوآوری تکمیلی، ارائه و ارزیابی تجربی یک منظم‌ساز صریح (منظم‌ساز بازسازی) برای مهار ریسک ذاتی این رویکرد-رانش خودرمزگذار-و مستندسازی محدودیت‌های این منظم‌ساز در بازهٔ وزن‌های بالای هدف ناوردایی است. سرانجام، طراحی و اجرای یک شبکهٔ آزمایشی نسبتاً گستردهٔ سه‌بُعدی (شرط × وزن × عمق لایه)، تصویری تجربی و دقیق از فضای رفتاری این روش-به‌جای گزارش صرف یک یا چند نتیجهٔ نقطه‌ای-فراهم کرده که مبنای انتخاب آگاهانهٔ یک پیکربندی متعادل

(به‌جای صرفاً بیشینه‌سازی یک سنجه) را برای کاربردهای آتی این روش ممکن می‌سازد.

۴.۵ محدودیت‌های پژوهش

صداقت علمی ایجاب می‌کند این پایان‌نامه محدودیت‌های خود را به‌روشنی بیان کند:

- **مقیاس مدل.** تمام آزمایش‌ها روی Pythia-70m-deduped، کوچک‌ترین عضو خانوادهٔ Pythia، انجام شده‌اند. این انتخاب برای اجرای شدنی شبکهٔ آزمایشی ۱۶۰ تایی در محدودهٔ منابع این پژوهش ضروری بود، اما مشخص نیست الگوهای مشاهده‌شده-به‌ویژه مصالحهٔ پایداری در وزن‌های بالا-به مدل‌های بزرگ‌تر با تعداد لایهٔ بیشتر و ابعاد بزرگ‌تر تعمیم می‌یابند یا خیر.
- **تک‌مدلی‌بودن نتایج.** تمام نتایج گزارش‌شده در این پایان‌نامه منحصراً به یک خانوادهٔ مدل (Pythia) تعلق دارند؛ در نتیجه، نمی‌توان دربارهٔ وابستگی یافته‌ها به معماری یا رویهٔ پیش‌آموزش مشخص این خانواده، در برابر خانواده‌های دیگر مدل‌های زبانی، ادعای مستقلی مطرح کرد.
- **طول آموزش کوتاه و مجموعه‌داده کوچک.** هر پیکربندی تنها بر روی تعداد محدودی گام و روی نمونه‌ای نسبتاً کوچک از PAWS آموزش دیده است. جهش‌های سرگشتگی گزارش‌شده در فصل چهارم (بخش ۴.۴) ممکن است تا حدی مختص این رژیم کوتاه‌مدت باشند؛ آموزش طولانی‌تر می‌تواند هم فرصت بیشتری برای ازسرگیری پایداری فراهم کند و هم-به‌طور بالقوه-رانش تدریجی‌تر و پایدارتر خودرمزگذار را آشکار سازد.

۵.۵ پیشنهادهایی برای پژوهش‌های آینده

بر پایهٔ یافته‌ها و محدودیت‌های بالا، مسیرهای زیر برای ادامهٔ این پژوهش پیشنهاد می‌شوند:

- **تکرار آزمایش‌ها روی مدل‌های بزرگ‌تر و خانواده‌های دیگر.** اجرای همین شبکهٔ آزمایشی (یا نسخه‌ای فشرده‌تر آن، با تمرکز بر بهترین نواحی شناسایی‌شده در این پایان‌نامه، از جمله ناحیهٔ پیکربندی توصیه‌شده) روی اعضای بزرگ‌تر خانوادهٔ Pythia و روی خانواده‌های دیگر مدل‌های زبانی، برای سنجش تعمیم‌پذیری یافته‌ها.

- **کاوش سازوکار مصالحهٔ پایداری.** بررسی دقیق‌تر اینکه چرا وزن بالا به ناپایداری در سرگشتگی می‌انجامد، و آزمودن راه‌حل‌های جایگزین-مانند جدا کردن کامل وزن منظم‌ساز بازسازی از وزن هدف ناوردایی، یا افزایش تدریجی این وزن در طول آموزش (زمان‌بندی گرم‌کردن[1])-برای رسیدن به بهبود بالا بدون این هزینه.

- **تحلیل کیفی ویژگی‌های تغییریافته.** شناسایی دستی اینکه کدام ویژگی‌های خاص خودرمزگذار، پیش و پس از ریزتنظیم، بیشترین نقش را در جداسازی هم‌معنی/ناهم‌معنی ایفا می‌کنند، و بررسی اینکه آیا این ویژگی‌ها با مفاهیم زبانی قابل‌فهم برای انسان (مانند ساختار نحوی یا نقش معنایی کلمات) متناظرند.

- **گسترش به مجموعه‌داده‌های دیگر شباهت معنایی.** آزمودن همین رویکرد روی مجموعه‌داده‌های دیگری فراتر از PAWS-مانند STS-B یا مجموعه‌داده‌های استلزام متنی-برای سنجش اینکه آیا یافته‌های این پایان‌نامه به ماهیت خاص جفت‌جمله‌های متخاصم PAWS محدودند یا به شکاف کلی‌تر میان شباهت لفظی و معنایی تعمیم می‌یابند.

۶.۵ سخن پایانی

این پایان‌نامه نشان داد که خودرمزگذارهای پراکنده-ابزاری که تا امروز عمدتاً برای فهمیدن مدل‌های زبانی ثابت به کار رفته‌اند-می‌توانند نقشی فعال‌تر نیز ایفا کنند: نقش یک فضای هدف که از طریق آن، مدل را می‌توان به‌طور مستقیم و هدفمند، در جهت یک سنجهٔ معنایی مشخص، ریزتنظیم کرد. نتایج این پایان‌نامه، در مقیاس محدود خود، از این ایده پشتیبانی می‌کنند، اما هم‌زمان نشان می‌دهند این سودمندی، رایگان به دست نمی‌آید: هر بهبودی که در سنجهٔ اصلی این پژوهش مشاهده شد، باید در کنار هزینه‌ای که برای پایداری آموزش پرداخت شد، خوانده شود، و همیشه بزرگ‌ترین بهبود خام، انتخاب عاقلانه‌ای نیست. امید است این تصویر متعادل-نه صرفاً گزارش بهترین نتیجهٔ خام، بلکه ترسیم کامل فضای مصالحه‌ها و معرفی یک نقطهٔ کار متعادل-زمینه‌ای برای پژوهش‌های دقیق‌تر و در مقیاس بزرگ‌تر آینده در همین جهت فراهم کند.

[1] Warm-up Schedule

کتاب‌نامه

[1] Biderman, Stella, Schoelkopf, Hailey, Anthony, Quentin, Bradley, Herbie, O'Brien, Kyle, Hallahan, Eric, Khan, Mohammad Aflah, Purohit, Shivanshu, Prashanth, USVSN Sai, Raff, Edward, Skowron, Aviya, Sutawika, Lintang, and van der Wal, Oskar. Pythia: A suite for analyzing large language models across training and scaling. In *Proceedings of the 40th International Conference on Machine Learning (ICML)*, pages 2397–2430, 2023.

[2] Black, Sidney, Biderman, Stella, Hallahan, Eric, Anthony, Quentin, Gao, Leo, Golding, Laurence, He, Horace, Leahy, Connor, McDonell, Kyle, Phang, Jason, Pieler, Michael, Prashanth, USVSN Sai, Purohit, Shivanshu, Reynolds, Laria, Tow, Jonathan, Wang, Ben, and Weinbach, Samuel. GPT-NeoX-20B: An open-source autoregressive language model. In *Proceedings of BigScience Episode #5 – Workshop on Challenges & Perspectives in Creating Large Language Models*, pages 95–136, 2022.

[3] Bloom, Joseph, Tigges, Curt, Duong, Anthony, and Chanin, David. SAELens. `https://github.com/jbloomAus/SAELens`, 2024.

[4] Bricken, Trenton, Templeton, Adly, Batson, Joshua, Chen, Brian, Jermyn, Adam, Conerly, Tom, Turner, Nicholas, Anil, Cem, Denison, Carson, Askell, Amanda, Lasenby, Robert, Wu, Yifan, Kravec, Shauna, Schiefer, Nicholas, Maxwell, Tim, Joseph, Nicholas, Hatfield-Dodds, Zac, Tamkin, Alex, Nguyen, Karina, McLean, Brayden, Burke, Josiah E, Hume, Tristan, Carter, Shan, Henighan, Tom, and Olah, Christopher. Towards monosemanticity: Decomposing language models with dictionary learning. *Transformer Circuits Thread*, 2023.

[5] Chen, Ting, Kornblith, Simon, Norouzi, Mohammad, and Hinton, Geoffrey. A simple framework for contrastive learning of visual representations. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, pages 1597–1607, 2020.

[6] Cunningham, Hoagy, Ewart, Aidan, Riggs, Logan, Huben, Robert, and Sharkey, Lee. Sparse autoencoders find highly interpretable features in language models. *arXiv preprint arXiv:2309.08600*, 2023.

[7] Devlin, Jacob, Chang, Ming-Wei, Lee, Kenton, and Toutanova, Kristina. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, pages 4171–4186, 2019.

[8] Elhage, Nelson, Hume, Tristan, Olsson, Catherine, Schiefer, Nicholas, Henighan, Tom, Kravec, Shauna, Hatfield-Dodds, Zac, Lasenby, Robert, Drain, Dawn, Chen, Carol, Grosse, Roger, McCandlish, Sam, Kaplan, Jared, Amodei, Dario, Wattenberg, Martin, and Olah, Christopher. Toy models of superposition. *Transformer Circuits Thread*, 2022.

[9] Elhage, Nelson, Nanda, Neel, Olsson, Catherine, Henighan, Tom, Joseph, Nicholas, Mann, Ben, Askell, Amanda, Bai, Yuntao, Chen, Anna, Conerly, Tom, DasSarma, Nova, Drain, Dawn, Ganguli, Deep, Hatfield-Dodds, Zac, Hernandez, Danny, Jones, Andy, Kernion, Jackson, Lovitt, Liane, Ndousse, Kamal, Amodei, Dario, Brown, Tom, Clark, Jack, Kaplan, Jared, McCandlish, Sam, and Olah, Chris. A mathematical framework for transformer circuits. *Transformer Circuits Thread*, 2021.

[10] Fawcett, Tom. An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.

[11] Gao, Leo, Biderman, Stella, Black, Sid, Golding, Laurence, Hoppe, Travis, Foster, Charles, Phang, Jason, He, Horace, Thite, Anish, Nabeshima, Noa, Presser, Shawn, and Leahy, Connor. The Pile: An 800GB dataset of diverse text for language modeling. *arXiv preprint arXiv:2101.00027*, 2020.

[12] Gao, Leo, la Tour, Tom Dupré, Tillman, Henk, Goh, Gabriel, Troll, Rajan, Radford, Alec, Sutskever, Ilya, Leike, Jan, and Wu, Jeffrey. Scaling and evaluating sparse autoencoders. *arXiv preprint arXiv:2406.04093*, 2024.

[13] Gao, Tianyu, Yao, Xingcheng, and Chen, Danqi. SimCSE: Simple contrastive learning of sentence embeddings. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6894–6910, 2021.

[14] Houlsby, Neil, Giurgiu, Andrei, Jastrzebski, Stanislaw, Morrone, Bruna, De Laroussilhe, Quentin, Gesmundo, Andrea, Attariyan, Mona, and Gelly, Sylvain. Parameter-efficient transfer learning for NLP. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pages 2790–2799, 2019.

[15] Hu, Edward J, Shen, Yelong, Wallis, Phillip, Allen-Zhu, Zeyuan, Li, Yuanzhi, Wang, Shean, Wang, Lu, and Chen, Weizhu. LoRA: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.

[16] Kantamneni, Subhash, Engels, Joshua, Rajamanoharan, Senthooran, Tegmark, Max, and Nanda, Neel. Are sparse autoencoders useful? a case study in sparse probing. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 2025.

[17] Khosla, Prannay, Teterwak, Piotr, Wang, Chen, Sarna, Aaron, Tian, Yonglong, Isola, Phillip, Maschinot, Aaron, Liu, Ce, and Krishnan, Dilip. Supervised contrastive learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 18661–18673, 2020.

[18] Kirkpatrick, James, Pascanu, Razvan, Rabinowitz, Neil, Veness, Joel, Desjardins, Guillaume, Rusu, Andrei A, Milan, Kieran, Quan, John, Ramalho, Tiago, Grabska-Barwinska, Agnieszka, Hassabis, Demis, Clopath, Claudia, Kumaran, Dharshan, and Hadsell, Raia. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.

[19] Lester, Brian, Al-Rfou, Rami, and Constant, Noah. The power of scale for parameter-efficient prompt tuning. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3045–3059, 2021.

[20] Li, Xiang Lisa and Liang, Percy. Prefix-tuning: Optimizing continuous prompts for generation. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL-IJCNLP)*, pages 4582–4597, 2021.

[21] Mikolov, Tomas, Chen, Kai, Corrado, Greg, and Dean, Jeffrey. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.

[22] Nanda, Neel and Bloom, Joseph. TransformerLens. `https://github.com/TransformerLensOrg/TransformerLens`, 2022.

[23] Ouyang, Long, Wu, Jeffrey, Jiang, Xu, Almeida, Diogo, Wainwright, Carroll, Mishkin, Pamela, Zhang, Chong, Agarwal, Sandhini, Slama, Katarina, Ray, Alex, Schulman, John, Hilton, Jacob, Kelton, Fraser, Miller, Luke, Simens, Maddie, Askell, Amanda, Welinder, Peter, Christiano, Paul, Leike, Jan, and Lowe, Ryan. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems (NeurIPS)*, 35:27730–27744, 2022.

[24] Rajamanoharan, Senthooran, Lieberum, Tom, Sonnerat, Nicolas, Conmy, Arthur, Varma, Vikrant, Kramár, János, and Nanda, Neel. Jumping ahead: Improving reconstruction fidelity with JumpReLU sparse autoencoders. *arXiv preprint arXiv:2407.14435*, 2024.

[25] Reimers, Nils and Gurevych, Iryna. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, 2019.

[26] Schroff, Florian, Kalenichenko, Dmitry, and Philbin, James. FaceNet: A unified embedding for face recognition and clustering. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 815–823, 2015.

[27] Templeton, Adly, Conerly, Tom, Marcus, Jonathan, Lindsey, Jack, Bricken, Trenton, Chen, Brian, Pearce, Adam, Citro, Craig, Ameisen, Emmanuel, Jones, Andy, Cunningham, Hoagy, Turner, Nicholas L, McDougall, Callum, MacDiarmid, Monte, Freeman, C Daniel, Sumers, Theodore R, Rees, Edward, Batson, Joshua, Jermyn, Adam, Carter, Shan, Olah, Chris, and Henighan, Tom. Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet. *Transformer Circuits Thread*, 2024.

[28] Turner, Alexander Matt, Thiergart, Lisa, Leech, Gavin, Udell, David, Vazquez, Juan J, Mini, Ulisse, and MacDiarmid, Monte. Steering language models with activation engineering. *arXiv preprint arXiv:2308.10248*, 2023.

[29] van den Oord, Aäron, Li, Yazhe, and Vinyals, Oriol. Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*, 2018.

[30] Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, Uszkoreit, Jakob, Jones, Llion, Gomez, Aidan N, Kaiser, Łukasz, and Polosukhin, Illia. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

[31] Wu, Zhengxuan, Arora, Aryaman, Geiger, Atticus, Wang, Zheng, Huang, Jing, Jurafsky, Dan, Manning, Christopher D, and Potts, Christopher. AxBench: Steering LLMs? even simple baselines outperform sparse autoencoders. *arXiv preprint arXiv:2501.17148*, 2025.

[32] Yang, Yinfei, Zhang, Yuan, Tar, Chris, and Baldridge, Jason. PAWS-X: A cross-lingual adversarial dataset for paraphrase identification. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, pages 3687–3692, 2019.

[33] Zhang, Yuan, Baldridge, Jason, and He, Luheng. PAWS: Paraphrase adversaries from word scrambling. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, pages 1298–1308, 2019.

[34] Zou, Andy, Phan, Long, Chen, Sarah, Campbell, James, Guo, Phillip, Ren, Richard, Pan, Alexander, Yin, Xuwang, Mazeika, Mantas, Dombrowski, Ann-Kathrin, Goel, Shashwat, Li, Nathaniel, Byun, Michael J, Wang, Zifan, Mallen, Alex, Basart, Steven, Koyejo, Sanmi, Song, Dawn, Fredrikson, Matt, Kolter, J Zico, and Hendrycks, Dan. Representation engineering: A top-down approach to AI transparency. *arXiv preprint arXiv:2310.01405*, 2023.

پیوست آ

ابرپارامترها و جزئیات پیاده‌سازی

این پیوست، جدول کامل ابرپارامترهای استفاده‌شده در تمام آزمایش‌های این پایان‌نامه را، تکمیل‌کنندهٔ بخش ۱۰.۳ از فصل سوم، فهرست می‌کند.

جدول آ.۴ کل شبکهٔ آزمایشی را-با تفکیک شرط و تعداد اجراهای هر شرط-خلاصه می‌کند.

یادداشتی درباره‌ٔ پیکربندی توصیه‌شده. همان‌طور که در فصل چهارم استدلال شد، پیکربندی توصیه‌شدهٔ این پایان‌نامه-شرط C4، لایهٔ هدف منفرد پنجم، و $\lambda = ۰/۳$-لزوماً همان پیکربندی‌ای نیست که بالاترین بهبود خام AUROC را در کل شبکهٔ آزمایشی به دست می‌دهد؛ این انتخاب بر مبنای مصالحه‌ای آگاهانه میان بهبود خام، سرگشتگی زبانی، و اعتبار بازسازی خودرمزگذار صورت گرفته است، نه صرفاً بیشینه‌سازی یک سنجهٔ منفرد.

جدول آ.۱: ابرپارامترهای مدل، لورا و بهینه‌سازی.

پارامتر	مقدار
مدل پایه	Pythia-70m-deduped
تعداد لایه‌ها	۶
ابعاد جریان باقیمانده	۵۱۲
رتبهٔ لورا (r)	۸
ضریب مقیاس لورا (α)	۱۶
دراپ‌اوت لورا	۰٫۰۵
ماژول‌های هدف لورا	query_key_value, dense
بهینه‌ساز	AdamW
نرخ یادگیری	$۱۰^{-۴}$
تعداد گام‌های آموزش	۵۰۰
بازهٔ ثبت چک‌پوینت	هر ۵۰ گام
کران بریدن نرم گرادیان	۱٫۰

جدول آ.۲: ابرپارامترهای دادگان.

پارامتر	مقدار
اندازهٔ دستهٔ WikiText در هر گام	۸ دنباله
طول هر دنبالهٔ WikiText	۲۵۶ نشانه
اندازهٔ دستهٔ PAWS در هر گام	۸ جفت هم‌معنی + ۸ جفت ناهم‌معنی
جفت‌های آموزش PAWS (هر شرط)	۴۰۰۰
جفت‌های اعتبارسنجی PAWS (هر شرط)	۳۰۰
جفت‌های آزمون PAWS (هر شرط)	۱۰۰۰

جدول آ.۳: ابرپارامترهای تابع هزینه و ارزیابی.

پارامتر	مقدار
وزن منظم‌ساز بازسازی خودرمزگذار	۱٫۰
کران بالای خطای بازسازی نرمال‌شده (رابطهٔ ۱.۳)	۱۰
مقادیر آزموده‌شدهٔ λ (شرایط C4-C2)	{۰٫۰۱, ۰٫۰۳, ۰٫۱, ۰٫۳, ۱٫۰}
بازهٔ مقیاس آموختنی BCE (γ)	[۱, ۵۰]
آستانهٔ هشدار اعتبار خودرمزگذار	۹۰٪
لایه(های) هدف آزموده‌شده	{۰}, {۱}, {۲}, {۳}, {۴}, {۵}, {۲, ۳}, {۳, ۴}, {۳, ۴, ۵}, {۴, ۵}

جدول آ.۴: ساختار کامل شبکهٔ آزمایشی. هر سطر، تعداد اجراهای مربوط به آن شرط را در هر یک از ده حالت انتخاب لایه نشان می‌دهد؛ عدد کل، حاصل‌ضرب این مقدار در ۱۰ است.

شرط	تعداد مقادیر λ	اجرا به ازای هر حالت لایه	کل اجراها (در ۱۰ حالت)
C1_lm_only	— (بدون λ)	۱	۱۰
C2_raw_invariance	۵	۵	۵۰
C3_sae_magnitude	۵	۵	۵۰
C4_sae_magnitude_support	۵	۵	۵۰
جمع اجراهای آموزشی			۱۶۰
خط پایه (بدون ریزتنظیم)			۱ (مشترک)

پیوست ب

جداول کامل نتایج

این پیوست، جداول تکمیلی نتایج فصل چهارم را، برای مراجعهٔ دقیق‌تر به خروجی کامل شبکهٔ آزمایشی، ارائه می‌دهد. یادآوری: پیکربندی‌های «بهترین» در جداول زیر، بر مبنای بیشترین بهبود خام AUROC تعیین شده‌اند، بدون درنظرگرفتن هزینهٔ آن‌ها از نظر سرگشتگی یا اعتبار خودرمزگذار؛ پیکربندی توصیه‌شدهٔ این پایان‌نامه (بخش ۵.۴) با این پیکربندی‌های «بهترین خام» یکسان نیست.

ب.۱ پیکربندی بهترین و بدترین بهبود خام، به ازای هر حالت انتخاب لایه

جدول ب.۱ برای هر یک از ده حالت انتخاب لایه، پیکربندی (شرط، λ) با بیشترین و کمترین میانگین بهبود AUROC در لایه(های) هدف را نشان می‌دهد.

نکتهٔ قابل‌توجه در این جدول، حضور مکرر شرط C2 (فضای خام) در ستون «کمترین بهبود» با مقادیر λ پایین است؛ این حضور، نشانهٔ خطا یا رفتار آسیب‌شناختی نیست، بلکه بازتاب همان یافتهٔ بخش ۲.۴ است که C2 به‌طور میانگین نزدیک به صفر عمل می‌کند و بنابراین، در نبود یک اثر نظام‌مند قوی، کدام پیکربندی خاص کمترین بهبود را داشته باشد را عمدتاً نوسان آماری کوچک تعیین می‌کند، نه یک سازوکار زیان سیستماتیک (برخلاف لایهٔ دوم در شرایط C4/C3 که زیانش بزرگ، پیوسته، و در بخش ۳.۴ توضیح داده شد). توجه شود که پیکربندی توصیه‌شدهٔ این پایان‌نامه (C4، لایهٔ ۵، $\lambda = ۰/۳$) در سطر «لایهٔ ۵» همان پیکربندی بیشترین بهبود خام نیز

جدول ب.۱: پیکربندی بهترین و بدترین بهبود خام، به ازای هر حالت انتخاب لایه.

لایه(های) هدف	بیشترین بهبود خام			کمترین بهبود خام		
	شرط	λ	بهبود	شرط	λ	بهبود
لایهٔ ۰	C2	۰٫۳	+۰٫۰۰۱۴	C3	۱	−۰٫۰۰۹۶
لایهٔ ۱	C3	۰٫۱	+۰٫۰۰۱۲	C3	۱	−۰٫۰۰۹۹
لایهٔ ۲	C1	۰	+۰٫۰۰۰۴	C3	۱	−۰٫۰۳۴۷
لایهٔ ۳	C4	۱	+۰٫۰۵۳۲	C4	۰٫۰۳	−۰٫۰۰۳۳
لایهٔ ۴	C4	۰٫۳	+۰٫۰۶۲۸	C2	۱	−۰٫۰۰۴۱
لایهٔ ۵	C4	۰٫۳	+۰٫۰۶۷۸	C2	۰٫۰۱	−۰٫۰۰۰۰
لایه‌های ۲ و ۳	C2	۱	+۰٫۰۱۰۴	C2	۰٫۱	−۰٫۰۱۴۲
لایه‌های ۳ و ۴	C3	۱	+۰٫۰۴۴۵	C2	۰٫۰۱	−۰٫۰۰۳۰
لایه‌های ۴ و ۵	C4	۰٫۳	+۰٫۰۵۷۲	C2	۰٫۰۱	−۰٫۰۰۵۳
لایه‌های ۳، ۴ و ۵	C3	۱	+۰٫۰۶۹۴	C2	۰٫۰۱	−۰٫۰۰۸۰

هست؛ در بقیهٔ سطرها، پیکربندی بیشترین بهبود خام لزوماً با معیارهای بخش ۵.۴ سازگار نیست.

ب.۲ میانگین بهبود بر حسب شرط و λ

جدول ب.۲ میانگین بهبود AUROC (در لایه(های) هدف، میانگین‌گیری‌شده روی هر ده حالت انتخاب لایه) را برای هر ترکیب شرط و λ نشان می‌دهد؛ این جدول، دادگان زیرین شکل ۱.۴ است.

برای مقایسه، C1 (بدون λ، اجرای منفرد) میانگین بهبود ۰٫۰۰۲۵− را در همین لایه‌ها به دست می‌آورد.

جدول ب.۲: میانگین بهبود AUROC، به تفکیک شرط و λ.

λ	C2 (خام)	C3 (SAE)	C4 (SAE+حمایت)
۰٫۰۱	−۰٫۰۰۳۶	−۰٫۰۰۱۹	−۰٫۰۰۱۴
۰٫۰۳	−۰٫۰۰۲۸	+۰٫۰۰۶۳	+۰٫۰۰۵۳
۰٫۱۰	−۰٫۰۰۳۴	+۰٫۰۲۶۷	+۰٫۰۲۳۷
۰٫۳۰	−۰٫۰۰۰۷	+۰٫۰۲۴۸	+۰٫۰۳۴۱
۱٫۰۰	+۰٫۰۰۴۳	+۰٫۰۳۰۰	+۰٫۰۲۹۱

ب.۳ اعتبار بازسازی خودرمزگذار در گام پایانی

جدول ب.۳ میانگین واریانس تبیین‌شدهٔ بازسازی را در گام پایانی آموزش، به تفکیک شرط و λ، تکمیل‌کنندهٔ شکل ۵.۴، نشان می‌دهد.

جدول ب.۳: میانگین واریانس تبیین‌شدهٔ بازسازی در گام پایانی، به تفکیک شرط و λ.

λ	C2 (خام)	C3 (SAE)	C4 (SAE+حمایت)
۰٫۰۱	۰٫۹۶۲۹	۰٫۹۶۱۳	۰٫۹۶۱۸
۰٫۰۳	۰٫۹۶۳۱	۰٫۹۵۰۳	۰٫۹۵۲۹
۰٫۱۰	۰٫۹۶۲۵	۰٫۹۳۰۴	۰٫۹۳۰۲
۰٫۳۰	۰٫۹۵۹۴	۰٫۹۲۰۰	۰٫۹۲۲۵
۱٫۰۰	۰٫۹۱۶۳	۰٫۸۹۲۹	۰٫۹۰۹۱

برای مقایسه، شرط C1 (فاقد هرگونه هدف ناوردایی) میانگین ۰٫۹۶۳۴ را به دست می‌آورد که نزدیک‌ترین مقدار به بالاترین ردیف جدول بالا (کمترین λ) است؛ این نزدیکی، خود، شاهدی است بر اینکه در λ بسیار کوچک، رفتار آموزش عملاً به رفتار شرط کنترلی همگرا می‌شود. سطر $\lambda = ۰٫۳۰$ در این جدول-پیکربندی توصیه‌شدهٔ این پایان‌نامه (بخش ۵.۴) دقیقاً از همین سطر، ستون C4، برآمده است-نشان می‌دهد در این نقطه، واریانس تبیین‌شده هنوز به‌خوبی بالاتر از آستانهٔ هشدار ٪۹۰ باقی می‌ماند؛ برخلاف سطر $\lambda = ۱٫۰۰$ که ستون C3 آن، از این آستانه عبور می‌کند.

واژه‌نامهٔ فارسی به انگلیسی

آ

آزمایش‌های شبکه‌ای . . . . . Grid Search

ا

استنتاج . . . . . Inference
اطلاعات فیشر . . . . . Fisher Information
ایستا . . . . . Static

ب

بازنمایی . . . . . Representations
بازنویسی . . . . . Paraphrase
بازنویسی‌های متخاصم برآمده از جابه‌جایی کلمات . Paraphrase Adversaries from Word Scrambling
بافتاری . . . . . Contextual
برهم‌نهی . . . . . Superposition
بریدن گرادیان . . . . . Gradient Clipping

پ

پردازش زبان طبیعی . . . . . Natural Language Processing
پیش‌آموزش . . . . . Pretraining

ت

تابع هزینهٔ ادراکی . . . . . Perceptual Loss
تابع هزینهٔ تقابلی . . . . . Contrastive Loss
تابع هزینهٔ سه‌تایی . . . . . Triplet Loss
تابع هزینهٔ ناوردایی . . . . . Invariance Loss
تجربی . . . . . Empirical
تحکیم وزن کشسان . . . . . Elastic Weight Consolidation, EWC
ترجمهٔ رفت‌وبرگشتی . . . . . Back-translation
ترنسفورمر . . . . . Transformer
تشخیص بازنویسی . Paraphrase Identification
تطبیق کم‌رتبه . Low-Rank Adaptation, LoRA
تفسیرپذیری . . . . . Interpretability
تفسیرپذیری مکانیستی . . . . . Mechanistic Interpretability
تک‌معنا . . . . . Monosemantic
توجه . . . . . Attention

ج

جریان باقیمانده . . . . . Residual Stream
جمعی . . . . . Additive

چ

چندمعنایی . . . . . Polysemanticity

ح

حاشیه . . . . . Margin
حذف‌تکرارشده . . . . . Deduplicated

خ

خودرمزگذار پراکنده Sparse Autoencoder, SAE

د

دایس . . . . . Dice
دما . . . . . Temperature
دوقلو . . . . . Siamese

ر

رانش خودرمزگذار . . . . . SAE Drift
رمزگشا-فقط . . . . . Decoder-only
ریزتنظیم . . . . . Fine-tuning
ریزتنظیم کارآمد پارامتر . . . Parameter-Efficient Fine-Tuning, PEFT

ز

زبان‌مدل‌سازی . . . . . Language Modeling
زمان‌بندی گرم‌کردن . . . . . Warm-up Schedule

س

سرگشتگی . . . . . Perplexity

ش

شباهت معنایی متن . . . . . Semantic Textual Similarity, STS

ف

فراجمع‌شونده . . . . . Super-additive
فراموشی فاجعه‌بار . . . Catastrophic Forgetting
فروپاشی بازنمایی . Representational Collapse
فروپاشی نمونه‌های منفی آسان . . Easy Negative Collapse
فضای نهان . . . . . Latent Space

ک

کاوش . . . . . Probing
کیسهٔ واژگان . . . . . Bag-of-words

م

مدارها . . . . . Circuits
مدل زبانی . . . . . Language Model
مدل‌های اسباب‌بازی . . . . . Toy Models
مشخصهٔ عملکرد گیرنده . . Receiver Operating Characteristic
مصالحه . . . . . Trade-offs
مطالعهٔ حذفی . . . . . Ablation Study
منجمد . . . . . Frozen
منظم‌ساز بازسازی Reconstruction Regularizer
مهندسی بازنمایی Representation Engineering

ن

نشانه . . . . . Token
نمونه‌های منفی سخت . . . . . Hard Negatives

و

ویژگی . . . . . Features
ویژگی‌های مرده . . . . . Dead Features

ه

هدایت . . . . . Steering
هم‌ارزی معنایی . . . . . Semantic Equivalence
همپوشانی تکیه‌گاه . . . . . Support Overlap

ی

یادگیری تقابلی . . . . . Contrastive Learning
یادگیری تقویتی مبتنی بر بازخورد انسانی . . . Reinforcement Learning from Human Feedback, RLHF
یادگیری فرهنگ‌لغت . . . . Dictionary Learning

واژه‌نامهٔ انگلیسی به فارسی

A

Ablation Study . . . . . مطالعهٔ حذفی
Additive . . . . . جمعی
Attention . . . . . توجه

B

Back-translation . . . . . ترجمهٔ رفت‌وبرگشتی
Bag-of-words . . . . . کیسهٔ واژگان

C

Catastrophic Forgetting . . . فراموشی فاجعه‌بار
Circuits . . . . . مدارها
Contextual . . . . . بافتاری
Contrastive Learning . . . . . یادگیری تقابلی
Contrastive Loss . . . . . تابع هزینهٔ تقابلی

D

Dead Features . . . . . ویژگی‌های مرده
Decoder-only . . . . . رمزگشا-فقط
Deduplicated . . . . . حذف‌تکرارشده
Dice . . . . . دایس
Dictionary Learning . . . . یادگیری فرهنگ‌لغت

E

Easy Negative . . فروپاشی نمونه‌های منفی آسان
Collapse
Elastic Weight . . . . . تحکیم وزن کشسان
Consolidation, EWC
Empirical . . . . . تجربی

F

Features . . . . . ویژگی
Fine-tuning . . . . . ریزتنظیم
Fisher Information . . . . . اطلاعات فیشر
Frozen . . . . . منجمد

G

Gradient Clipping . . . . . بریدن گرادیان
Grid Search . . . . . آزمایش‌های شبکه‌ای

H

Hard Negatives . . . . . نمونه‌های منفی سخت

I

استنتاج . . . . . Inference
تابع هزینهٔ ناوردایی . . . . . Invariance Loss
تفسیرپذیری . . . . . Interpretability

L

مدل زبانی . . . . . Language Model
زبان‌مدل‌سازی . . . . . Language Modeling
فضای نهان . . . . . Latent Space
تطبیق کم‌رتبه . Low-Rank Adaptation, LoRA

M

حاشیه . . . . . Margin
تفسیرپذیری مکانیستی . . . . . Mechanistic Interpretability
تک‌معنا . . . . . Monosemantic

N

پردازش زبان طبیعی . . . . . Natural Language Processing

P

ریزتنظیم کارآمد پارامتر . . . Parameter-Efficient Fine-Tuning, PEFT
بازنویسی . . . . . Paraphrase
بازنویسی‌های متخاصم برآمده از جابه‌جایی کلمات . Paraphrase Adversaries from Word Scrambling
تشخیص بازنویسی . Paraphrase Identification
تابع هزینهٔ ادراکی . . . . . Perceptual Loss
سرگشتگی . . . . . Perplexity
چندمعنایی . . . . . Polysemanticity
چندمعنایی . . . . . Polysemy
پیش‌آموزش . . . . . Pretraining
کاوش . . . . . Probing

R

مشخصهٔ عملکرد گیرنده . . Receiver Operating Characteristic
منظم‌ساز بازسازی Reconstruction Regularizer
یادگیری تقویتی مبتنی بر بازخورد انسانی . . . Reinforcement Learning from Human Feedback, RLHF
مهندسی بازنمایی Representation Engineering
فروپاشی بازنمایی . Representational Collapse
بازنمایی . . . . . Representations
جریان باقیمانده . . . . . Residual Stream

S

رانش خودرمزگذار . . . . . SAE Drift
هم‌ارزی معنایی . . . . . Semantic Equivalence
شباهت معنایی متن . . . . . Semantic Textual Similarity, STS
فراجمع‌شونده . . . . . Super-additive
برهم‌نهی . . . . . Superposition
هم‌پوشانی تکیه‌گاه . . . . . Support Overlap
دوقلو . . . . . Siamese
خودرمزگذار پراکنده Sparse Autoencoder, SAE
ایستا . . . . . Static
هدایت . . . . . Steering

T

دما . . . . . Temperature
مدل‌های اسباب‌بازی . . . . . Toy Models
نشانه . . . . . Token
مصالحه . . . . . Trade-offs
ترنسفورمر . . . . . Transformer
تابع هزینهٔ سه‌تایی . . . . . Triplet Loss

W

زمان‌بندی گرم‌کردن . . . . . Warm-up Schedule

Abstract

Large language models learn their vector representations primarily to predict the next token, an objective that does not necessarily shape sentence representations along the semantic axes that matter to humans. The PAWS dataset exposes this gap starkly: sentence pairs with very high lexical overlap that are labeled as either paraphrases or non-paraphrases.

This thesis proposes a parameter-efficient fine-tuning method in which an invariance loss – pulling paraphrastic pairs together and pushing non-paraphrastic pairs apart – is applied not to the model's raw residual-stream activations, but to the latent codes produced by passing those activations through a frozen, pretrained sparse autoencoder (SAE). This choice is motivated by the phenomenon of feature superposition in the raw activation space of language models, which makes the effect of a direct invariance pressure in that space unpredictable.

The method is implemented on Pythia-70m-deduped with a LoRA adapter and evaluated across a systematic experimental grid: four experimental conditions (a no-invariance control, raw-space invariance, SAE-space invariance, and an augmented variant of the latter), five values of the invariance-loss weight, and ten choices of target layer(s), for a total of 160 independent training runs.

Results show that applying the invariance loss in the SAE latent space consistently produces better separation between paraphrastic and non-paraphrastic pairs (measured by area under the ROC curve) than applying the same loss in the raw activation space, or than applying no invariance loss at all. This improvement depends strongly on the depth of the targeted layer (mid-to-late layers, not early ones) and on the loss weight, and targeting multiple layers simultaneously has a super-additive effect. However, the largest gains coincide with transient training instability and a measurable drop in SAE reconstruction fidelity; the proposed regularizer fully controls this cost at low loss weights but only partially at high ones. Accordingly, this thesis identifies a balanced configuration – a more moderate loss weight – that achieves nearly the same gain without this cost. By presenting this balanced picture – rather than reporting only the best raw result – this thesis introduces a new use for sparse autoencoders, beyond their conventional role in post-hoc interpretability.

Keywords Language Models, Sparse Autoencoders, Parameter-Efficient Fine-Tuning, Contrastive Learning, Paraphrase Identification, Mechanistic Interpretability

University of Tehran
College of Engineering
School of Electrical and
Computer Engineering

Fine-Tuning Language Models for Semantic Invariance in the Latent Space of Sparse Autoencoders

Bachelor of Science Thesis in Computer Engineering

By:

Reza Chehreghani

Supervisor:

Dr. Mostafa Tavassolipour

2026